

2d. Grundlagen

Optimalitätsbedingungen

Optimierung SoSe 2020

Dr. Alexey Agaltsov



Plan

- Allgemeine Optimalitätsbedingungen
- Optimalitätsbedingungen für konvexe Programme
- Starke Konvexität



Optimalitätsbedingungen

$$\begin{array}{l} \text{Minimiere } f(x) \\ U \subseteq \mathbb{R}^n \text{ offen, } f \in C^1(U) \end{array}$$

- Wie kann man die optimalen Lösungen erkennen?
- Notwendige Optimalitätsbedingungen (NOB):

Sei x_ ein lokales/globales Minimum, so gilt ...*

- Hinreichende Optimalitätsbedingungen (HOB):

Erfülle $x_ \in U$..., so ist x_* ein lokales/globales Minimum*

Bemerkung: Maximierungsprobleme

- Der Einfachheit halber werden wir die Theorie nur für die Minimierungsprobleme entwickeln
- Notwendige Modifikationen für Maximierungsprobleme sind geradlinig
- In Beispielen wird eventuell Maximierung von Funktionen auftreten



Erinnerung: Taylor-Formel

- Seien $f \in C^1(U)$, U offen und konvex, $x, x + p \in U$. Dann:

$$\exists \xi \in [0,1]: f(x + p) = f(x) + \underline{\nabla f(x + \xi p)^T p}$$

Restglied nach Lagrange

- Ist weiterhin $f \in C^2(U)$, so gilt:


$$1. \quad \exists \eta \in [0,1]: f(x + p) = f(x) + \nabla f(x)^T p + \overbrace{p^T \nabla^2 f(x + \eta p) p}$$

$$2. \quad \nabla f(x + p) = \nabla f(x) + \underbrace{\int_0^1 \nabla^2 f(x + tp) p \, dt}$$

Restglied in Integralform



Wann ist x_* ein lokales Minimum von $f \in C^1$?



Tangentialebene bei x_* ist horizontal

- x_* heißt **stationärer Punkt** von f falls $\nabla f(x_*) = 0$
- **Lemma.** Sei $U \subseteq \mathbb{R}^n$ offen, $f \in C^1(U)$. Ist $x_* \in U$ ein lokales Minimum so gilt $\nabla f(x_*) = 0$



Beweis

$$\{x \in \mathbb{R}^n: \|x - x_*\|_2 < \varepsilon\}$$

$$\exists \varepsilon > 0: \overline{B_\varepsilon(x_*)} \subseteq U, f(x_*) \leq f(x) \quad \forall x \in B_\varepsilon(x_*)$$

$$\text{Seien } d \in \underbrace{S_1(0)}, t \in (0, \varepsilon)$$

$$\{x \in \mathbb{R}^n: \|x\|_2 = 1\}$$

$\exists \xi \in [0,1]$
Taylor-Formel

$$\underbrace{f(x_* + td) - f(x_*)}_{\geq 0} = t \nabla f(x_* + \xi td)^T d$$

$$\nabla f(x_* + \xi td)^T d \geq 0$$

$t \rightarrow 0$
 $f \in C^1(U)$

$$\nabla f(x_*)^T d \geq 0$$


$$d = -\nabla f(x_*) / \|\nabla f(x_*)\|_2$$

$$-\|\nabla f(x_*)\|_2 = 0$$




Wann ist x_* ein lokales Minimum von $f \in C^2$?


Ist $\nabla f(x_*) = 0$, so kann x_* kein lokales Minimum sein



$$f''(0) > 0$$



$$f''(0) < 0$$




$$f''(0) = 0$$


Für $f \in C^2(U)$ kann man diese Fälle unterscheiden !

Wann ist x_* ein lokales Minimum von $f \in C^2$?


$$y = x_1^2 + x_2^2$$



$$\nabla^2 f(x_*) > 0$$



$$\nabla^2 f(x_*) < 0$$



$$\nabla^2 f(x_*) \text{ indefinit}$$

Lemma. Sei $U \subseteq \mathbb{R}^n$ offen, $f \in C^2(U)$, $x_* \in U$ ein Punkt mit $\nabla f(x_*) = 0$

1. Sei x_* ein lokales Minimum, so gilt $\nabla^2 f(x_*) \geq 0$
2. Gelte $\nabla^2 f(x_*) > 0$, so ist x_* ein striktes lokales Minimum



Beweis: x_* ein lokales Min. $\Rightarrow \nabla^2 f(x_*) \succcurlyeq 0$

$$\exists \varepsilon > 0: B_\varepsilon(x_*) \subseteq U, f(x_*) \leq f(x) \quad \forall x \in B_\varepsilon(x_*)$$

$$\text{Seien } d \in S_1(0), t \in (0, \varepsilon)$$

$$\exists \eta \in [0, 1] \quad \text{Taylor-Formel}$$

$$\underbrace{f(x_* + td) - f(x_*)}_{\geq 0} = \underbrace{t \nabla f(x_*)^T d}_0 + \frac{1}{2} t^2 d^T \nabla^2 f(x_* + \eta td) d$$

$$d^T \nabla^2 f(x_* + \xi td) d \geq 0$$

$$d^T \nabla^2 f(x_*) d \geq 0$$

$$\begin{matrix} t \rightarrow 0 \\ f \in C^2(U) \end{matrix}$$

$$\text{Also } \nabla^2 f(x_*) \succcurlyeq 0$$

Beweis: zu 2

Behauptung. $\nabla f(x_*) = 0, \nabla^2 f(x_*) \succ 0 \Rightarrow$ ist x_* ein striktes lokales Minimum

$$\exists \varepsilon > 0: \nabla^2 f(x) \succ 0 \quad \forall x \in B_\varepsilon(x_*)$$

Sei $d \in B_\varepsilon(0) \setminus \{0\}$:

$$\exists \eta \in [0,1]$$

Taylor-Formel

$$f(x_* + d) = f(x_*) + \underbrace{\nabla f(x_*)^T d}_0 + \underbrace{d^T \nabla^2 f(x_* + \eta d) d}_{> 0}$$

$$f(x) > f(x_*) \quad \forall x \in B_\varepsilon(x_*) \setminus \{x_*\}$$



Geometrische Interpretation in 2D


- $\nabla^2 f(x, y)$ ist die Matrix der zweiten Fundamentalform des Graphen

$$z = f(x, y)$$

- $\nabla^2 f(x, y)e_i = \lambda_i e_i$ für $i = 1, 2$ mit $e_i \neq 0$

λ_1, λ_2 sind Hauptkrümmungen

e_1, e_2 sind Hauptkrümmungsrichtungen



Satz 2.19. Optimalitätsbedingungen

Sei U offen, $f \in C^1(U)$. Dann gelten die folgenden Aussagen:

- Ist $x_* \in U$ ein lokales Minimum von f , so gilt $\nabla f(x_*) = 0$
Ist weiterhin $f \in C^2(U)$, so gilt $\nabla^2 f(x_*) \geq 0$
- Ist $x_* \in U$ ein Punkt mit $\nabla f(x_*) = 0, \nabla^2 f(x_*) \succ 0$, so ist x_* ein striktes lokales Minimum von f

Notwendige Optimalitätsbedingungen (NOB)

Mithilfe der NOB kann man das globale Minimum von f finden:

- Bestimme alle Punkte die NOB erfüllen
- Wähle von denen den Punkt x_* mit minimalem Zielfunktionswert
- Nimmt f ihr Minimum an, so ist x_* ein Minimum von f

Beispiel: Nichtexistenz von Lösungen

- **Vorsicht:** Zuerst muss man die Existenz von Lösungen feststellen

$$\text{Minimiere } f(x) = x^2 - x^4$$

$$\begin{aligned} f'(x) &= 2x - 4x^3 \\ &= 3x(1 - \sqrt{2}x)(1 + \sqrt{2}x) \end{aligned}$$

$$f''(x) = 2 - 12x^2$$




Beispiel: Nichtexistenz von Lösungen

$$f'(x) = 0 \quad \text{für } x \in \{0, \pm 1/\sqrt{2}\}$$

$$f''(0) = 2 \quad \text{lokales Minimum}$$

$$f''(\pm 1/\sqrt{2}) = -4 \quad \text{lokale Maxima}$$

$$f(x) \rightarrow -\infty \quad \text{für } x \rightarrow \pm\infty$$



Plan

- Allgemeine Optimalitätsbedingungen
- Optimalitätsbedingungen für konvexe Programme
- Starke Konvexität

Optimierung über konvexe Mengen

Minimiere $f(x)$ über $x \in K$

$f \in C^1(\mathbb{R}^n)$, $K \subseteq \mathbb{R}^n$ konvex


- Wir nehmen an, x_* ist eine optimale Lösung
- Ist x_* ein innerer Punkt von K , so gilt nach Satz 2.19:

$$\nabla f(x_*) = 0$$

- Was ist die Optimalitätsbedingung für ein allgemeines x ?



Optimalitätsbedingung für konvexe Funktionen



$$-\nabla f(x_*)^T (x - x_*) \leq 0 \quad \forall x \in K$$

Satz 2.20. Optimalitätsbedingungen für konvexe Funktionen

Sei $K \subseteq \mathbb{R}^n$ konvex und $f \in C^1(\mathbb{R}^n)$

- Ist $x_* \in K$ ein lokales Minimum von f auf K , so gilt:

$$-\nabla f(x_*)^T (x - x_*) \leq 0 \quad \forall x \in K$$

- Seien f konvex und $x_* \in K$ ein Punkt, der die obige Bedingung erfüllt
Dann ist x_* ein globales Minimum von f auf K

Beweis: zu 1

Sei x_* ein lokales Minimum von f auf K

Seien $x \in K$ und $t \in (0,1)$

$\exists \xi \in [0,1]$

Taylor-Formel

$$\underline{f(x_* + t(x - x_*)) - f(x_*) = t \nabla f(x_* + \xi t(x - x_*))^T (x - x_*)}$$

≥ 0 für $t \in (0, \varepsilon)$

$$\nabla f(x_* + \xi t(x - x_*))^T (x - x_*) \geq 0 \quad t \in (0, \varepsilon)$$

lasse $t \rightarrow 0$

$f \in C^1(\mathbb{R}^n)$

$$\nabla f(x_*)^T (x - x_*) \geq 0$$



Beweis: zu 2

Sei f konvex und $x_* \in K$ ein Punkt, sodass:

$$-\nabla f(x_*)^T (x - x_*) \leq 0 \quad \forall x \in K$$

Satz 2.17

$$\geq 0$$

$$f(x) - f(x_*) \geq \overline{\nabla f(x_*)^T (x - x_*)}$$

$$f(x) \geq f(x_*)$$

x ist beliebig

x_* ist ein globales Minimum von f auf K



Aufgabe 2.21. Quadratische Programme

$$\begin{aligned} \text{Minimiere } f(x) &= \frac{1}{2}x^T Qx - c^T x + r \text{ über } x \in \mathbb{R}^n \\ Q &\in \mathbb{S}_{\succcurlyeq}^n, c \in \mathbb{R}^n, r \in \mathbb{R} \end{aligned}$$

Beweisen Sie die folgenden Aussagen:

- Ist f nach unten beschränkt, so gibt es eine optimale Lösung
- $x_* \in \mathbb{R}^n$ ist eine optimale Lösung $\Leftrightarrow Qx_* = c$



Plan

- Allgemeine Optimalitätsbedingungen
- Optimalitätsbedingungen für konvexe Programme
- **Starke Konvexität**

Starke Konvexität

Minimiere $f(x)$ über $x \in U$

$U \subseteq \mathbb{R}^n$ offen und konvex

$f \in C^2(U)$ konvex

- Wir nehmen an, es gibt eine eindeutige Lösung $x_* \in U$
- Also ist x_* durch $\nabla f(x_*) = 0$ gekennzeichnet
- Sei $x \in U$ ein Punkt mit $\|\nabla f(x)\|_2 < \varepsilon$

Wie kann man $\|x - x_\|_2$ und $f(x) - f(x_*)$ durch ε abschätzen?*

Starke Konvexität

Notation: $\forall X, Y \in \mathbb{S}^n$ setzen wir $X \succcurlyeq Y$ falls $(X - Y) \succcurlyeq 0$

- $f \in C^2(U)$ heißt **stark konvex** falls $\exists m > 0$, sodass:

$$\nabla^2 f(x) \succcurlyeq mI \quad \forall x \in U$$

- Gilt $\nabla^2 f(x_*) \succ 0$, so ist f stark konvex neben x_*
- Ist f stark konvex, so kann man die Optimalitätskriterien quantifizieren

Lemma 2.22. Starke Konvexität

Sei $U \subseteq \mathbb{R}^n$ offen und konvex, $f \in C^2(U)$. Wir nehmen an:

- f ist stark konvex mit Konstante $m > 0$
- $x_* \in U$ ist ein Minimum von f auf U und $f_* = f(x_*)$

Dann gelten die folgenden Abschätzungen:

1. $f(y) \geq f(x) + \nabla f(x)(y - x) + \frac{m}{2} \|y - x\|_2^2 \quad \forall x, y \in U$
2. $f(x) - f_* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2 \quad \forall x \in U$
3. $\|x - x_*\|_2 \leq \frac{2}{m} \|\nabla f(x)\|_2 \quad \forall x \in U$

Beweis: zu 1

Behauptung: $f(y) \geq f(x) + \nabla f(x)(y - x) + \frac{m}{2}\|y - x\|_2^2 \quad \forall x, y \in U$

Sei $f \in C^2(U)$, $\nabla^2 f \succcurlyeq mI$

Seien $x, y \in U$

$\exists z \in [x, y]$
Taylor-Formel

$$\begin{aligned} f(y) &= f(x) + \nabla f(x)(y - x) + \underbrace{\frac{1}{2}(y - x)^T \nabla^2 f(z)(y - x)}_{\geq \frac{m}{2}\|y - x\|_2^2} \end{aligned}$$



Beweis: zu 2

Behauptung: $f(x) - f_* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2 \quad \forall x \in U$

$$f(y) \geq \underbrace{f(x) + \nabla f(x)(y - x) + \frac{m}{2}\|y - x\|_2^2}_{g(y)} \quad \forall x, y \in U$$

$$\nabla f(x) + m(y_* - x) = 0 \quad \leftarrow \text{minimiere } g(y)$$

$$y_* = x - \frac{1}{m}\nabla f(x)$$

$$f(y) \geq g(y_*) = f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2$$

$$f_* \geq f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2$$

$y := x_*$



Beweis: zu 3

Behauptung: $\|x - x_*\|_2 \leq \frac{2}{m} \|\nabla f(x)\|_2 \quad \forall x \in U$

$$\geq f(x_*)$$

$$f(x_*) \geq \overbrace{f(x)} + \underbrace{\nabla f(x)(x_* - x)} + \frac{m}{2} \|x - x_*\|_2^2 \quad \forall x \in U \setminus \{x_*\}$$

$$\geq -\|\nabla f(x)\|_2 \|x - x_*\|_2 \quad (\text{Cauchy-Schwarz})$$

$$0 \geq -\|\nabla f(x)\|_2 \|x - x_*\|_2 + \frac{m}{2} \|x - x_*\|_2^2$$

dividiere durch
 $\|x - x_*\|_2$

$$\|x - x_*\|_2 \leq \frac{2}{m} \|\nabla f(x)\|_2$$



Geometrische Interpretation


$$\{x \in \mathbb{R}^n : \|x\|_2 = 1\}$$

- Sei $K \subseteq \mathbb{R}^n$ konvex und $d \in \overline{S_1^n(0)}$
- Die **Breite** von K in der Richtung d

$$W(K, d) = S_K(d) + S_K(-d)$$

Stützfunktion

$$S_K(d) = \sup_{x \in K} d^T x$$



Maximale und minimale Breite


$$W_{max}(K) = \sup_{\|d\|_2=1} W(K, d)$$

$$W_{min}(K) = \inf_{\|d\|_2=1} W(K, d)$$

- Als **die Kondition** von K bezeichnet man

$$\kappa(K) := \frac{W_{max}^2(K)}{W_{min}^2(K)}$$

- Durch $\kappa(K)$ wird die Asymmetrie von K gemessen



Beispiel: Ellipsoid

$$\mathcal{E} = \{x: (x - x_*)^T \Sigma^{-1} (x - x_*) \leq 1\} \quad \Sigma \in \mathbb{S}_{>}^n$$

Aufgabe 2.15


$$S_{\mathcal{E}}(d) = d^T x_* + \|\Sigma^{1/2} d\|_2$$

$$W(\mathcal{E}, d) = S_{\mathcal{E}}(d) + S_{\mathcal{E}}(-d) = 2\|\Sigma^{1/2} d\|_2$$

$$W_{\max}(\mathcal{E}) = 2\sqrt{\lambda_{\max}} \text{ — max. Eigenwert von } \Sigma$$

$$W_{\min}(\mathcal{E}) = 2\sqrt{\lambda_{\min}} \text{ — min. Eigenwert von } \Sigma$$

$$\kappa(\mathcal{E}) = \frac{W_{\max}^2(\mathcal{E})}{W_{\min}^2(\mathcal{E})} = \frac{\lambda_{\max}}{\lambda_{\min}} = \kappa(\Sigma) \quad \text{Kondition von } \Sigma$$



Satz 2.23. Kondition der Unterniveau-Mengen

Sei $f \in C^2(\mathbb{R}^n)$ und $S = \{x: f(x) \leq \alpha\}$ mit $\alpha \in \mathbb{R}$. Wir nehmen an:

- $\nabla^2 f \succcurlyeq mI$ auf S (bzw. $\nabla^2 f \preccurlyeq MI$ auf S)
- x_* ist ein globales Minimum von f und $f_* = f(x_*)$

Dann gilt:

$$W_{max}^2(S) \leq \frac{2}{m}(\alpha - f_*) \quad (\text{bzw. } W_{min}^2(S) \geq \frac{2}{M}(\alpha - f_*))$$

Gelte gleichzeitig $mI \preccurlyeq \nabla^2 f \preccurlyeq MI$ auf S , so gilt:

$$\kappa(S) \leq \frac{M}{m}$$

Beweis

Behauptung: $\nabla^2 f \succcurlyeq mI$ auf $S \Rightarrow W_{max}^2(S) \leq \frac{2}{m}(\alpha - f_*)$


$$f_* + \underbrace{\nabla f(x_*)^T (x - x_*)}_0 + \frac{m}{2} \|x - x_*\|_2^2 \leq f(x) \quad \forall x \in S \quad (\text{Lemma 2.22})$$

$$\underbrace{f(x) \leq \alpha}_{x \in S} \quad \curvearrowright \quad f_* + \frac{m}{2} \|x - x_*\|_2^2 \leq \alpha$$

$$\|x - x_*\|_2^2 \leq \frac{2}{m}(\alpha - f_*)$$

$$x \in \overline{B_R}(x_*), \quad R = \sqrt{\frac{2}{m}(\alpha - f_*)}$$

$$S \subseteq \overline{B_R}(x_*) \quad \longrightarrow \quad W_{max}(S) \leq R$$



Beweis

Behauptung: $mI \leq \nabla^2 f \leq MI$ auf $S \implies \kappa(S) \leq \frac{M}{m}$

$$W_{\min}^2(S) \geq \frac{2}{M}(\alpha - f_*)$$

$$W_{\max}^2(S) \leq \frac{2}{m}(\alpha - f_*)$$

$$\kappa(S) := \frac{W_{\max}^2(S)}{W_{\min}^2(S)} \leq \frac{M}{m}$$



Zusammenfassung

- Allgemeine Optimalitätsbedingungen
- Optimalitätsbedingungen für konvexe Programme
- Starke Konvexität

Nächstes Video

- 3a. Abstiegsverfahren: Definition und Schrittweitenwahl