

# 4a. Newton-artige Verfahren

## Das Newton-Verfahren

Optimierung SoSe 2020

Dr. Alexey Agaltsov



# Plan

- Die Newton-Richtung
- Das Newton-Verfahren
- Konvergenz



# Mathematisches Programm

Minimiere  $f(x)$  über  $x \in U$

$f \in C^2(U)$ ,  $U \subseteq \mathbb{R}^n$  offen

- Man kann dieses Problem mit dem Gradientenverfahren lösen
- Das benötigt nur die ersten Ableitungen von  $f$  und garantiert lineare Konvergenz
- Benutzt man auch die zweiten Ableitungen, so kann man ein effizienteres Verfahren erstellen

*Newton-Verfahren*



# Das Newton-Verfahren

Das Newton-Verfahren lässt verschiedene Herleitungen zu:

- Löse die Optimalitätsbedingung  $\nabla f(x) = 0$  für  $x_*$  mit dem Newton-Verfahren für nichtlineare Gleichungen
- Minimiere konsekutive quadratische Approximationen an  $f$



# Newton-Verfahren für nichtlineare Gleichungen

Löse  $g(x) = 0$


$$g \in C^1(\mathbb{R})$$

linearisiere

$$g(x_k) + g'(x_k)(x - x_k) = 0$$

aktuelle Näherungslösung

$$x_{k+1} := x_k - \frac{g(x_k)}{g'(x_k)}$$



# Newton-Verfahren für Optimierungsprobleme

Minimiere  $f(x)$  über  $x \in \mathbb{R}$

$$f \in C^2(\mathbb{R})$$

Optimalitätsbedingung

$$f'(x) = 0$$

Newton-Verfahren

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

# Quadratische Approximation

Minimiere  $f(x)$  über  $x \in \mathbb{R}$


$$f \in C^2(\mathbb{R})$$

quadratische Approximation

$$\text{Minimiere } g(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2}f''(x_k)(x - x_k)^2$$

aktuelle Approximation

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$



# Mehrdimensionaler Fall

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$   
 $f \in C^2(\mathbb{R}^n)$

quadratische  
Approximation

Minimiere  $g(x)$  über  $x \in \mathbb{R}^n$

$$g(x) = f(x_k) + \nabla f(x_k)(x - x_k) + \frac{1}{2}(x - x_k)^T \nabla^2 f(x_k)(x - x_k)$$

aktuelle Approximation

Optimalitätsbedingung

$$\nabla f(x_k) + \nabla^2 f(x_k)(x_{k+1} - x_k) = 0$$

$$x_{k+1} = x_k - \nabla^2 f(x_k)^{-1} \nabla f(x_k)$$



# Die Newton-Schritt

- Als **Newton-Schritt** bezeichnen wir die Aufdatierungsformel:

$$x_{k+1} = x_k - \nabla^2 f(x_k)^{-1} \nabla f(x_k)$$

- Als **Newton-Richtung** im Punkt  $x_k$  bezeichnen wir:

$$d_k = -\nabla^2 f(x_k)^{-1} \nabla f(x_k)$$


# Die Newton-Richtung

$$d_k = -\nabla^2 f(x_k)^{-1} \nabla f(x_k), \quad \nabla f(x_k) \neq 0$$

- Sei  $\nabla^2 f(x_k) \succ 0$ , so ist die Newton-Richtung  $d_k$  eine Abstiegsrichtung:

$$-\nabla f(x_k)^T d_k = \nabla f(x_k)^T \nabla^2 f(x_k)^{-1} \nabla f(x_k) > 0$$

**Vorsicht:** Ist  $\nabla^2 f(x_k) \not\succ 0$ , so kann  $d$  keine Abstiegsrichtung sein



# Plan

- Die Newton-Richtung
- **Das Newton-Verfahren**
- Quadratische Konvergenz



# Koordinatentransformation

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$   
 $f \in C^2(\mathbb{R}^n)$

Minimiere  $\bar{f}(\bar{x})$  über  $\bar{x} \in \mathbb{R}^n$

$$\bar{x} := P^{1/2}x \text{ mit } P \in \mathbb{S}_{>}^n$$
$$\bar{f}(\bar{x}) := f(P^{-1/2}\bar{x}) = f(x)$$

- Die Newton-Richtung in  $\bar{x}$  ist:

$$\bar{d} = -\nabla^2 \bar{f}(\bar{x})^{-1} \nabla \bar{f}(\bar{x}) = -P^{1/2} \nabla^2 f(x)^{-1} \nabla f(x)$$

- Die entsprechende Richtung in  $x$  ist:

$$d = P^{-1/2} \bar{d} = -\nabla^2 f(x)^{-1} \nabla f(x)$$

*Die Newton-Richtung ist linear- (und sogar affin-) invariant*

*Das NV ist unempfindlich ggb. der Kondition der Unterniveau-Mengen*



# Abbruchsregel

- Sei  $x_k$  eine aktuelle Näherungslösung und  $\varepsilon > 0$  ein Toleranzwert
- Gewöhnliches Abbruchskriterium  $\|\nabla f(x_k)\|_2 < \varepsilon$
- Es wäre wünschenswert, eine affin-invariante Abbruchsregel bei dem Newton-Verfahren zu haben



# Das Newton-Dekrement

- Als **Newton-Dekrement** am Punkt  $x_k$  bezeichnen wir:

$$\begin{aligned}\lambda(x_k) &= \|\nabla f(x_k)\|_{\nabla^2 f(x_k)^{-1}} \\ &= \left( \nabla f(x_k)^T \nabla^2 f(x_k)^{-1} \nabla f(x_k) \right)^{1/2}\end{aligned}$$

- Das Newton-Dekrement ist affin-invariant
- Affin-invariante Abbruchsregel:

$$\lambda(x_k) < \varepsilon \implies \text{Breche die Iteration ab}$$

# Das Newton-Verfahren

1. *Initialisierung*: Startwert  $x_0 \in \mathbb{R}^n$ , Toleranzwert  $\epsilon > 0$
2. **for**  $k = 0, 1, 2, \dots$  **do**:
3.     **if**  $\lambda(x_k) < \epsilon$  **then** break
4.      $x_{k+1} = x_k - \nabla^2 f(x_k)^{-1} \nabla f(x_k)$
5. **end for**



# Beispiel: 1D

Minimiere  $f(x) = x - \log x$  über  $x > 0$

$$f'(x) = 1 - \frac{1}{x} \implies x_* = 1 \text{ ist stationär}$$

$$f''(x) = \frac{1}{x^2} > 0 \implies f \text{ ist strikt konvex}$$


$x_*$  ist die optimale Lösung

$$d(x) = -\left(\frac{1}{x^2}\right)^{-1} \left(1 - \frac{1}{x}\right) = x - x^2$$

$$x_{k+1} = x_k + (x_k - x_k^2) = 2x_k - x_k^2$$



# Beispiel: 1D



$$x_{k+1} = 2x_k(1 - \frac{x_k}{2})$$

$$x_0 \in (0, 2) \Rightarrow x_k \rightarrow 1$$

$$x_0 = 2 \Rightarrow x_k \equiv 2$$



# Beispiel: 2D

Minimiere  $f(x_1, x_2) = -\log(1 - x_1 - x_2) - \log(x_1) - \log(x_2)$   
über  $x_1, x_2 > 0, x_1 + x_2 < 1$


$$\nabla f(x_1, x_2) = \begin{bmatrix} \frac{1}{1-x_1-x_2} - \frac{1}{x_1} \\ \frac{1}{1-x_1-x_2} - \frac{1}{x_2} \end{bmatrix} \Rightarrow \text{stationärer Punkt } x_1^* = x_2^* = \frac{1}{3}$$

$$\nabla^2 f(x_1, x_2) = \begin{bmatrix} \left(\frac{1}{1-x_1-x_2}\right)^2 + \left(\frac{1}{x_1}\right)^2 & \left(\frac{1}{1-x_1-x_2}\right)^2 \\ \left(\frac{1}{1-x_1-x_2}\right)^2 & \left(\frac{1}{1-x_1-x_2}\right)^2 + \left(\frac{1}{x_2}\right)^2 \end{bmatrix} \succ 0$$

$\Rightarrow f$  ist konvex       $(\frac{1}{3}, \frac{1}{3})$  ist die optimale Lösung



# Beispiel: 2D



$$x^0 = (0.6, 0.1), \quad x^* = \left(\frac{1}{3}, \frac{1}{3}\right)$$

$k$	$\ x^k - x^*\ _2$	$f(x^k) - f_*$	$c^k$
0	0,35	0,72	
1	0,18	0,21	0,4
2	0,07	0,029	0,66
3	0,009	0,00044	0,53
4	0,00011	6,9E-08	0,36

$$f(x^k) - f_* = c^k (f(x^{k-1}) - f_*)^2$$

Wir werden auch theoretisch zeigen, dass die Konvergenz quadratisch ist

# Plan

- Die Newton-Richtung
- Das Newton-Verfahren
- Konvergenz

# Mathematisches Program

$$\begin{aligned} &\text{Minimiere } f(x) \text{ über } x \in \mathbb{R}^n \\ &f \in C^2(\mathbb{R}^n) \end{aligned}$$

- Sei  $x_*$  eine optimale Lösung
- Sei  $x_0, x_1, \dots$  eine mit dem Newton-Verfahren erzeugte Folge
- Was bestimmt die Konvergenz und ihre Geschwindigkeit?

# Was bestimmt die Konvergenz?

Hauptfaktoren, die die Konvergenz bestimmen:

- Qualität der quadratischen Approximation
- Wie nahe  $x_0$  an  $x_*$  liegt
- Positive Definitheit der Hesse-Matrix



# Qualität der quadratischen Approximation

$$f(x) \approx f(x_k) + \nabla f(x_k)^T (x - x_k) + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k)$$

- Die Approximation ist gut falls  $\nabla^2 f(x)$  sich langsam ändert
- Lipschitz-Stetigkeit von  $\nabla^2 f(x)$  quantifiziert es durch  $L > 0$ :

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq L \|x - y\|_2$$



# Beispiel: Quadratische Zielfunktion

Minimiere  $f(x) = \frac{1}{2}x^T Qx - c^T x + r$  mit  $Q \in \mathbb{S}_{>}^n$

$$\nabla f(x) = Qx - c$$

$$\nabla^2 f(x) = Q \succ 0$$

- Nach Aufgabe 2.21 ist  $x_* = Q^{-1}c$  ein eindeutiges globales Minimum
- Das Newton-Verfahren findet  $x_*$  in einem Schritt  $\forall x_0$ :

$$\begin{aligned}x_1 &= x_0 - Q^{-1}(Qx_0 - c) \\ &= Q^{-1}c\end{aligned}$$



# Wahl des Startwertes

- Die Methode des steilsten Abstiegs bzgl.  $\|\cdot\|_P$  konvergiert schnell falls

$$P^{-1/2}(\nabla^2 f)P^{-1/2} \approx I \quad \text{auf } S = \{x: f(x) \leq f(x_0)\}$$

- Ist  $x_0 \approx x_*$ , so ist  $P = \nabla^2 f(x_*)$  eine optimale Wahl
- Die Newton-Richtung in  $x$  ist die Richtung des steilsten Abstiegs bzgl.  $\|\cdot\|_P$  mit  $P = \nabla^2 f(x)$

*schnelle Konvergenz für  $x_0 \approx x_*$*

# Positive Definitheit der Hesse-Matrix

$$d = -\nabla^2 f(x)^{-1} \nabla f(x)$$

- $\nabla^2 f(x)$  muss regulär sein, damit ist  $d$  wohldefiniert
- $\nabla^2 f(x) \succ 0$  garantiert, dass  $d$  eine Abstiegsrichtung ist
- $\nabla^2 f(x) \succcurlyeq mI$  lässt die Konvergenzgeschwindigkeit abschätzen

*Konvergenzgeschwindigkeit steigt mit  $m$*

# Satz 4.1. Quadratische Konvergenz

Sei  $f \in C^2(\mathbb{R}^n)$  und sei  $x_*$  ein lokales Minimum. Angenommen:

- $\nabla^2 f(x) \succcurlyeq mI \succ 0 \quad \forall x \in B_\delta(x_*)$
- $\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq L\|x - y\|_2 \quad \forall x, y \in B_\delta(x_*)$

Qualität der quadratischen  
Approximationen

Ist  $\|x_0 - x_*\|_2 < \min\left(\delta, \frac{2m}{L}\right)$ , so gilt:

$$\|x_{k+1} - x_*\|_2 \leq \frac{L}{2m} \|x_k - x_*\|^2 \quad \forall k \geq 0$$



# Beweis

$$r_k := x_* - x_k$$

Ziel: Drücke  $r_{k+1}$  durch  $r_k$  aus

$$\begin{aligned} r_{k+1} &= r_k + \nabla^2 f(x_k)^{-1} \nabla f(x_k) && \xrightarrow{\nabla f(x_*) = 0} \\ &= r_k - \nabla^2 f(x_k)^{-1} (\nabla f(x_*) - \nabla f(x_k)) && \xrightarrow{\text{Taylor-Formel}} \\ &= r_k - \nabla^2 f(x_k)^{-1} \int_0^1 \nabla^2 f(x_k + r_k t) r_k dt \\ &= \nabla^2 f(x_k)^{-1} \int_0^1 [\nabla^2 f(x_k) - \nabla^2 f(x_k + r_k t)] r_k dt \end{aligned}$$



# Beweis

Behauptung:  $\|r_{k+1}\|_2 \leq \frac{L}{2m} \|r_k\|_2^2$

$$r_{k+1} = \nabla^2 f(x_k)^{-1} \int_0^1 [\nabla^2 f(x_k) - \nabla^2 f(x_k + r_k t)] r_k dt$$

$$\|r_{k+1}\|_2 \leq \underbrace{\|\nabla^2 f(x_k)^{-1}\|_2}_{\leq \frac{1}{m}} \int_0^1 \underbrace{\|\nabla^2 f(x_k) - \nabla^2 f(x_k + r_k t)\|_2}_{\leq L\|r_k\|_2 t} \|r_k\|_2 dt$$

$$\|r_{k+1}\|_2 \leq \frac{L}{m} \int_0^1 \|r_k\|_2^2 t dt \leq \frac{L}{2m} \|r_k\|_2^2$$



# Globale Konvergenz

- Das Newton-Verfahren entspricht den Schrittweiten  $\alpha_k \equiv 1$
- Liegt  $x_0$  weit von  $x_*$  so kann die Konvergenz fehlschlagen
- Schrittweitenstrategien können die Konvergenz globalisieren

*Gedämpftes Newton-Verfahren*

# Zusammenfassung

- Die Newton-Richtung
- Das Newton-Verfahren
- Quadratische Konvergenz



# Nächstes Video

- 4b. Newton-artige Verfahren: Quasi-Newton-Verfahren

