

4c. Newton-artige Verfahren

Ausgleichsprobleme

Optimierung SoSe 2020

Dr. Alexey Agaltsov



Plan

- Lineares Ausgleichsproblem
- Nichtlineares Ausgleichsproblem
- Konvergenz des Gauß-Newton-Verfahrens



Lineares Ausgleichsproblem

Minimiere $f(x) = \frac{1}{2} \|Ax - y\|_2^2$ über $x \in \mathbb{R}^n$

$$A \in \mathbb{R}^{m \times n}, y \in \mathbb{R}^m$$

a_i i -te Zeile von A
 $y = (y_1, \dots, y_m)$

Minimiere $f(x) = \frac{1}{2} \sum_{i=1}^m (a_i^T x - y_i)^2$ über $x \in \mathbb{R}^n$

- x_* ist eine optimale Lösung $\Leftrightarrow Ax_*$ ist die Projektion von y auf $\text{im } A$
- Der Optimalwert ist gleich 0 $\Leftrightarrow y \in \text{im } A$

Existenz von Lösungen

$$\begin{aligned} f(x) &= \frac{1}{2} \|Ax - b\|_2^2 \\ &= \frac{1}{2} x^T A^T A x - x^T A^T b + \frac{1}{2} b^T b \end{aligned}$$

- f ist quadratisch und f ist beschränkt nach unten ($f \geq 0$)
 - Es gibt eine optimale Lösung x_*
 - x_* ist eine optimale Lösung $\Leftrightarrow x_*$ erfüllt die **Normalgleichung**
- Aufgabe 2.21

$$A^T A x_* = A^T b \quad (\text{Aufgabe 2.21})$$




Die Pseudo-Inverse

$$A^T A x_* = A^T y$$

- Sei $\ker A = \{0\}$, sodass $A^T A \succ 0$

$$x_* = \underbrace{(A^T A)^{-1} A^T}_{A^+} y$$



- A^+ heißt die (Moore-Penrose) **Pseudo-Inverse** von A

$$A^+ y = \operatorname{argmin}_x \{\|Ax - y\|_2\}$$

Statistische Interpretation

- Lineares Messmodell:

a_i i -te Zeile von A

$y = (y_1, \dots, y_m)$

$\varepsilon = (\varepsilon_1, \dots, \varepsilon_m)$

bekannt unbekannte Parameterwerte

$$\underbrace{y_i}_{\text{Messwerte}} = \underbrace{a_i^T}_{\text{bekannt}} \underbrace{x}_{\text{unbekannte Parameterwerte}} + \underbrace{\varepsilon_i}_{\text{Messfehler}} \quad i = 1, \dots, m$$

Messwerte Messfehler

$y = Ax + \varepsilon$

- Bestimme x

Distribution der Messfehler

- Seien ε_i unabhängige Zufallsvariablen von $N(0, \sigma^2)$:

„ $\mathbb{P}(\varepsilon_1 = t_1, \dots, \varepsilon_m = t_m)$ “ = $\frac{1}{(2\pi\sigma^2)^{m/2}} \prod_{i=1}^m \exp\left(-\frac{t_i^2}{2\sigma^2}\right)$
Wahrscheinlichkeitsdichtefunktion = $\frac{1}{(2\pi\sigma^2)^{m/2}} \exp\left(-\frac{\|t\|_2^2}{2\sigma^2}\right)$ $t = (t_1, \dots, t_m)$

- Der Vektor ε hat die mehrdimensionale Normalverteilung $N(0, \Sigma)$

$$\Sigma = \text{diag}(\sigma^2, \dots, \sigma^2)$$



Maximum-Likelihood-Methode

- Für welches x ist die Realisierung $\varepsilon = y - Ax$ von $N(0, \Sigma)$ möglichst wahrscheinlich?

Maximiere „ $\mathbb{P}(\varepsilon = y - Ax)$ “ über $x \in \mathbb{R}^n$

Minimiere $-\log(\text{„}\mathbb{P}(\varepsilon = y - Ax)\text{“})$ über $x \in \mathbb{R}^n$

Minimiere $\frac{1}{2\sigma^2} \|Ax - y\|_2^2$ über $x \in \mathbb{R}^n$

$$\text{„}\mathbb{P}\text{“} = \frac{1}{(2\pi\sigma^2)^{m/2}} \exp\left(-\frac{\|t\|_2^2}{2\sigma^2}\right)$$



Beispiel: Lineare Regression

- $R_i \in \mathbb{R}$ Rendite des Investmentfonds PRSVX für die Woche $i = 1, \dots, m$
Von 15/01/2010 bis 27/12/2013
- $R_i^M \in \mathbb{R}$ die Marktrendite für die Woche i
- Gibt es einen Zusammenhang zwischen R_i und R_i^M ?

Lineare Regression

$$R_i = \alpha + \beta R_i^M + \underline{\varepsilon_i}$$


Rauschen

$$y = (R_1, \dots, R_m)^T$$

$$x = (\alpha, \beta)^T$$

$$A = \begin{bmatrix} 1 & R_1^M \\ \vdots & \vdots \\ 1 & R_m^M \end{bmatrix}$$

$$y = Ax + \varepsilon$$



Wöchentliche Renditen



Aufgabe 4.6. Lineare Regression

Minimiere $f(\alpha, \beta) = \frac{1}{2} \sum_{i=1}^m (R_i - \alpha - \beta R_i^M)^2$ über $\alpha, \beta \in \mathbb{R}$

- Wir nehmen an, es gibt $i \neq j$ mit $R_i^M \neq R_j^M$
- Zeigen Sie, dass es eine eindeutige optimale Lösung α_*, β_* gibt, sodass:

$$\beta_* = \frac{\sum_{i=1}^m (R_i^M - \overline{R^M})(R_i - \bar{R})}{\sum_{i=1}^m (R_i^M - \overline{R^M})^2} \quad \alpha_* = \bar{R} - \beta_* \overline{R^M}$$

$$\bar{R} = (R_1 + \dots + R_m)/m, \quad \overline{R^M} = (R_1^M + \dots + R_m^M)/m$$

Verzerrung-Varianz-Dilemma

Minimiere $f(x) = \frac{1}{2} \|Ax - y\|_2^2$ über $x \in \mathbb{R}^n$

$$\ker A = \{0\}, \quad x_* = (A^T A)^{-1} A^T y$$

- Seien die Spalten von A fast linear abhängig, so ist $(A^T A)^{-1}$ groß

Die Messfehler in y werden verstärkt

x_ spiegelt das Rauschen wider (Überanpassung)*

- Finde einen geeigneten Ausgleich zwischen Empfindlichkeit auf Rauschen (*Varianz*) und Modellfehler (*Verzerrung*)

Falsche Beziehung zwischen x und y (Unteranpassung)

Tikhonov-Regularisierung

Minimiere $\|Ax - y\|_2^2 + \alpha \|x\|_2^2$ über $x \in \mathbb{R}^n$

$$A \in \mathbb{R}^{m \times n}, y \in \mathbb{R}^m, \alpha > 0$$

Minimiere $\left\| \begin{bmatrix} A \\ \sqrt{\alpha}I \end{bmatrix} x - \begin{bmatrix} y \\ 0 \end{bmatrix} \right\|_2^2$ über $x \in \mathbb{R}^n$

$$x_* = (A^T A + \alpha I)^{-1} A^T y$$

- Die Kondition $\kappa(A^T A + \alpha I)$ fällt mit α
- Ist $\kappa(A^T A + \alpha I) = N$, so wird der Fehler in $A^T y \approx$ um Faktor N verstärkt



Aufgabe 4.7. Kondition fällt mit α

- Sei $A \in \mathbb{R}^{m \times n}$ mit $\ker A = \{0\}$.
- **Singulärwerte** von $A \in \mathbb{R}^{m \times n}$ sind die Eigenwerte von $(A^T A)^{1/2}$
Ist $A \in \mathbb{S}_{>}^n$ so stimmen die Singulärwerte mit Eigenwerten überein
- Die Kondition von A ist definiert durch:

$$\kappa(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)} \quad \begin{array}{l} \text{--- max. Singulärwert von } A \\ \text{--- min. Singulärwert von } A \end{array}$$

- Beweisen Sie die folgende Formel:

$$\kappa(A^T A + \alpha I) = \frac{\sigma_{\max}^2(A) + \alpha}{\sigma_{\min}^2(A) + \alpha} \quad \alpha \geq 0$$

Plan

- Lineares Ausgleichsproblem
- Nichtlineares Ausgleichsproblem
- Konvergenz des Gauß-Newton-Verfahrens

Beispiel: Radioaktiver Zerfall

- Zwei radioaktive Substanzen werden in den Boden eingebracht
- y_i Zerfälle pro Minute werden zum Zeitpunkt t_i gemessen, $i = 1, \dots, m$
- Bestimme die Anfangsaktivitäten A_1, A_2 und die Halbwertszeiten T_1, T_2

$$y_i = A_1 2^{-t_i/T_1} + A_2 2^{-t_i/T_2} + \underbrace{\varepsilon_i}_{\text{Messfehler}}, \quad i = 1, \dots, m$$

Methode der kleinsten Quadrate

$$y_i = A_1 2^{-t_i/T_1} + A_2 2^{-t_i/T_2} + \varepsilon_i, \quad i = 1, \dots, m$$

Bestimme A_1, A_2, T_1, T_2

- Wähle A_1, A_2, T_1, T_2 , sodass $\sum_{i=1}^m \varepsilon_i^2$ minimal ist

$$F_i(A_1, A_2, T_1, T_2) := A_1 2^{-t_i/T_1} + A_2 2^{-t_i/T_2}$$

Minimiere $\frac{1}{2} \sum_{i=1}^m (F_i(A_1, A_2, T_1, T_2) - y_i)^2$

über $A_1, A_2, T_1, T_2 \in \mathbb{R}$



Nichtlineares Ausgleichsproblem

Minimiere $f(x) = \frac{1}{2} \|F(x) - y\|_2^2$ über $x \in \mathbb{R}^n$

$$F \in C^1(\mathbb{R}^n, \mathbb{R}^m), \quad y \in \mathbb{R}^m$$

- Sei x_* eine optimale Lösung
- Das **Gauß-Newton-Verfahren** versucht x_* näherungsweise zu bestimmen
- Die Konvergenz ist lokal quadratisch, falls das Problem kompatibel ist:

$$F(x_*) = y$$

Konvergenzgeschwindigkeit fällt mit $\|F(x_) - y\|_2$*

Gauß-Newton-Verfahren

Zwei Herleitungen:

- Wende das Newton-Verfahren mit einer Approximation an die Hesse-Matrix von f an
- Linearisiere F neben der aktuellen Näherungslösung und löse das resultierende quadratische Program für eine neue Näherungslösung

Ableitungen

$$f(x) = \frac{1}{2} \sum_{i=1}^m (F_i(x) - y_i)^2$$

$$\frac{\partial f}{\partial x_i} = \sum_{k=1}^m \frac{\partial F_k}{\partial x_i} (F_k(x) - y_k)$$

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \sum_{k=1}^m \left[\frac{\partial^2 F_k}{\partial x_i \partial x_j} (F_k(x) - y_k) + \frac{\partial F_k}{\partial x_i} \frac{\partial F_k}{\partial x_j} \right] \approx \frac{\partial F_k}{\partial x_i} \frac{\partial F_k}{\partial x_j}$$

Ableitungen in Vektorform

$$DF = \begin{bmatrix} \frac{\partial F_1}{\partial x_1} & \dots & \frac{\partial F_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial F_m}{\partial x_1} & \dots & \frac{\partial F_m}{\partial x_n} \end{bmatrix}$$

$$f(x) = \frac{1}{2} (F(x) - y)^T (F(x) - y)$$

$$\nabla f(x) = DF(x)^T (F(x) - y)$$

$$\nabla^2 f(x) \approx DF(x)^T DF(x)$$



Erste Herleitung

Minimiere $f(x) = \frac{1}{2}\|F(x) - y\|_2^2$ über $x \in \mathbb{R}^n$

$$F \in C^2(\mathbb{R}^n, \mathbb{R}^m), y \in \mathbb{R}^m$$

Newton-Verfahren

$$x_{k+1} = x_k - \nabla^2 f(x_k)^{-1} \nabla f(x_k)$$

aktuelle Approximation

$$\nabla f(x_k) = DF(x_k)^T (F(x_k) - y)$$

$$\nabla^2 f(x_k) \approx DF(x_k)^T DF(x_k) \succ 0$$

$$x_{k+1} = x_k - \underbrace{\left(DF(x_k)^T DF(x_k) \right)^{-1} DF(x_k)^T}_{DF(x_k)^+} (F(x_k) - y)$$

Alternative Herleitung

Minimiere $f(x) = \frac{1}{2}\|F(x) - y\|_2^2$

$F \in C^1(\mathbb{R}^n, \mathbb{R}^m), y \in \mathbb{R}^m$

linearisiere F

Minimiere $\frac{1}{2}\|F(x_k) + DF(x_k)(x - x_k) - y\|_2^2$

aktuelle Approximation

lineares Ausgleichsproblem

$$DF(x_k)^T DF(x_k)(x_{k+1} - x_k) = -DF(x_k)^T (F(x_k) - y)$$

$$x_{k+1} = x_k - DF(x_k)^+ (F(x_k) - y)$$

$\ker DF(x_k) = \{0\}$

Gauß-Newton-Verfahren

1. *Initialisierung*: Startwert $x_0 \in \mathbb{R}^n$, Toleranzwert $\epsilon > 0$
2. **for** $k = 0, 1, 2, \dots$ **do**:
 $\|DF(x_k)^T (F(x_k) - y)\|_2$
3. **if** $\|\nabla f(x_k)\|_2 < \epsilon$ **then** break
4. $x_{k+1} = x_k - DF(x_k)^+ (F(x_k) - y)$
5. **end for**

Plan

- Lineares Ausgleichsproblem
- Nichtlineares Ausgleichsproblem
- Konvergenz des Gauß-Newton-Verfahrens

Satz 4.8. Lokale Konvergenz

Sei $F \in C^1(\mathbb{R}^n, \mathbb{R}^m)$ und $x_* \in \operatorname{Argmin}_x \|F(x) - y\|_2^2$. Angenommen:

- $\operatorname{rang}(DF(x)) = n \quad \forall x \in B_\delta(x_*) \quad \longrightarrow \quad DF(x)^T DF(x) > 0$
- $\|DF(x)^+(DF(x) - DF(y))\|_2 \leq \omega \|x - y\|_2 \quad \forall x, y \in B_\delta(x_*)$
- $\|DF(x)^+(F(x_*) - y)\|_2 \leq \kappa \|x - x_*\|_2$ mit $\kappa \in [0, 1)$ $\forall x \in B_\delta(x_*)$
 $\quad \quad \quad \nearrow$ ist $F(x_*) = y$, so gilt es mit $\kappa = 0$

Ist $\|x_0 - x_*\|_2 < \min\{\frac{2}{\omega}(1 - \kappa), \delta\}$, so gilt:

$$\|x_{k+1} - x_*\|_2 \leq \frac{\omega}{2} \|x_k - x_*\|_2^2 + \kappa \|x_k - x_*\|_2$$

Beweis

- Ohne Beschränkung der Allgemeinheit: $x_* = 0, y = 0$

$$\begin{aligned}x_{k+1} &= x_k - DF(x_k)^+ F(x_k) \quad \searrow \pm DF(x_k)^+ F(0) \\&= x_k - DF(x_k)^+ (F(x_k) - F(0)) - DF(x_k)^+ F(0) \\&\quad \searrow x_k = DF(x_k)^+ DF(x_k) x_k \\&= -DF(x_k)^+ (F(x_k) - F(0) - DF(x_k) x_k) - DF(x_k)^+ F(0) \\&\quad \searrow \text{Taylor-Formel für } x_k \text{ und } 0 \\&= -\int_0^1 DF(x_k)^+ (DF(tx_k) - DF(x_k)) x_k dt - DF(x_k)^+ F(0)\end{aligned}$$



Beweis

$$\|DF(x_k)^+ F(0)\|_2 \leq \kappa \|x_k\|_2$$

↗ Annahme

$$x_{k+1} = - \int_0^1 \underbrace{DF(x_k)^+ (DF(tx_k) - DF(x_k))}_{\text{Annahme}} x_k dt - \overline{DF(x_k)^+ F(0)}$$

$$\|DF(x_k)^+ (DF(tx_k) - DF(x_k))\|_2 \leq \omega(1-t) \|x_k\|_2$$

$$\begin{aligned} \|x_{k+1}\|_2 &\leq \int_0^1 \omega(1-t) \|x_k\|_2^2 dt + \kappa \|x_k\|_2 \\ &= \frac{1}{2} \omega \|x_k\|_2^2 + \kappa \|x_k\|_2 \end{aligned}$$



Lemma 4.9. Konvergenzgeschwindigkeit

$$\|DF(x)^+(F(x_*) - y)\|_2 \leq \kappa \|x - x_*\|_2 \text{ mit } \kappa \in [0,1) \quad \forall x \in B_\delta(x_*)$$
$$\Rightarrow \|x_{k+1} - x_*\|_2 \leq \frac{\omega}{2} \|x_k - x_*\|_2^2 + \kappa \|x_k - x_*\|_2$$

Die Bedingung ist erfüllt mit $\kappa = \varepsilon L$, falls:

$$\|DF(x)^+ - DF(x_*)^+\|_2 \leq L \|x - x_*\|_2 \text{ für } x \in B_\delta(x_*)$$

$$\|F(x_*) - y\|_2 = \varepsilon < \frac{1}{L} \text{ Rauschpegel in Messwerten}$$

- Quadratische Konvergenz für exakte Daten: $\varepsilon = 0$
- Die Konvergenzgeschwindigkeit fällt mit steigendem ε



Beweis

Behauptung: $\|DF(x)^+(F(x_*) - y)\|_2 \leq \kappa \|x - x_*\|_2$ mit $\kappa \in [0,1)$

$$f(x) = \frac{1}{2} \|F(x) - y\|_2^2$$

$$\nabla f(x_*) = DF(x_*)^T (F(x_*) - y) = 0$$

$$DF(x_*)^+(F(x_*) - y) = 0$$

$$\|DF(x)^+(F(x_*) - y)\|_2 = \|(DF(x)^+ - DF(x_*)^+)(F(x_*) - y)\|_2$$

$$\leq \underbrace{\|DF(x)^+ - DF(x_*)^+\|_2}_{\leq L\|x - x_*\|_2} \underbrace{\|F(x_*) - y\|_2}_{\varepsilon}$$

$$\leq \underbrace{L\varepsilon}_{\kappa < 1} \|x - x_*\|_2$$



Stabilität

Minimiere $f(x) = \frac{1}{2}\|F(x) - y\|_2^2$ über $x \in \mathbb{R}^n$
 $F \in C^1(\mathbb{R}^n, \mathbb{R}^m)$, $y \in \mathbb{R}^m$

- Oft sind sind Matrizen $DF(x)^T DF(x)$ **schlecht konditioniert**, d.h.

$\kappa(DF(x)^T DF(x))$ ist groß

- Der Fehler in Messwerten y wird beim Gauß-Newton-Schritt verstärkt :

$$x_{k+1} = x_k - \left(DF(x_k)^T DF(x_k)\right)^{-1} DF(x_k)^T (F(x_k) - y)$$

- Die Iterationen akkumulieren die Fehler

Levenberg-Marquardt-Verfahren

Minimiere $f(x) = \frac{1}{2} \|F(x) - y\|_2^2$ über $x \in \mathbb{R}^n$

$F \in C^1(\mathbb{R}^n, \mathbb{R}^m), y \in \mathbb{R}^m$

linearisiere F

Minimiere $\|F(x_k) + DF(x_k)(x - x_k) - y\|_2^2$

aktuelle Näherungslösung

Anpassungsparameter > 0

Minimiere $\|F(x_k) + DF(x_k)(x - x_k) - y\|_2^2 + \alpha_k \|x - x_k\|_2^2$

*Ausgleich zwischen Empfindlichkeit auf
Messfehler und Modellqualität*

$$x_{k+1} = x_k - (DF(x_k)^T DF(x_k) + \alpha_k)^{-1} DF(x_k)^T (y - F(x_k))$$



Zusammenfassung

- Lineares Ausgleichsproblem
- Nichtlineares Ausgleichsproblem
- Konvergenz des Gauß-Newton-Verfahrens

Nächstes Video

5a. Lineare Nebenbedingungen: Gleichungen

