



# 5c. Lineare Nebenbedingungen

## Lagrange-Dualität

Optimierung SoSe 2020  
Dr. Alexey Agaltsov



# Plan

- Lagrange-Dualität
- Dualität für restringierte Optimierungsprobleme
- Beispiel: Support Vector Machines



# Primales und duales Problem

- Sei  $\mathcal{L}: A \times B \rightarrow \mathbb{R}$  gegeben
- Als **primales Problem** bezeichnen wir:


Minimiere  $F(x)$ ,  $x \in A$   
(u.d.N.  $F(x) < \infty$ )

*Primale Funktion*  $F(x) = \sup_{\lambda \in B} \mathcal{L}(x, \lambda)$

- Als **duales Problem** bezeichnen wir:

Maximiere  $G(\lambda)$ ,  $\lambda \in B$   
(u.d.N.  $G(\lambda) > -\infty$ )

*Duale Funktion*  $G(\lambda) = \inf_{x \in A} \mathcal{L}(x, \lambda)$



# Satz 5.13. Schwache Dualität

Seien  $F, G$  die primale bzw. die duale Funktionen. Dann gilt:

$$G(\lambda) \leq F(x) \quad \forall x \in A, \lambda \in B$$

*Beweis:*

$$\underbrace{\inf_{y \in A} \mathcal{L}(y, \lambda)}_{G(\lambda)} \leq \mathcal{L}(x, \lambda) \leq \underbrace{\sup_{u \in B} \mathcal{L}(x, u)}_{F(x)} \quad \forall x \in A, \forall \lambda \in B$$



# $\varepsilon$ -Suboptimalität

$$F_* = \inf_{x \in A} F(x)$$

- Ein Punkt  $x \in A$  heißt  **$\varepsilon$ -suboptimal** falls:

$$F(x) - F_* < \varepsilon$$

- Jeder Punkt  $\lambda \in B$  entspricht einer Abschätzung:

$$F_* \geq G(\lambda)$$

- Seien  $x \in A, \lambda \in B$  so, dass  $F(x) - G(\lambda) < \varepsilon$ . Dann ist  $x$   $\varepsilon$ -suboptimal



# Starke Dualität

$$F_* = \inf_{x \in A} F(x), \quad G_* = \sup_{\lambda \in B} G(\lambda)$$

- Als **Dualitätslücke** bezeichnen wir:

$$F_* - G_* \geq 0$$

- Die **starke Dualität** ist erfüllt, falls:

$$F_* = G_*$$



# Beispiel: Positive Dualitätslücke

- Sei  $\mathcal{L}(x, \lambda)$  in der folgenden Tabelle aufgeführt:

$x \setminus \lambda$	1	2
1	1	0
2	0	1

$$F(x) = \sup_{\lambda \in \{1,2\}} \mathcal{L}(x, \lambda) \equiv 1$$

$$G(\lambda) = \inf_{x \in \{1,2\}} \mathcal{L}(x, \lambda) \equiv 0$$

$$F_* - G_* = 1$$




# Sattelpunkte

$(x_*, \lambda_*) \in A \times B$  heißt **Sattelpunkt** von  $\mathcal{L}$  falls:

$$\mathcal{L}(x, \lambda_*) \leq \mathcal{L}(x_*, \lambda_*) \leq \mathcal{L}(x_*, \lambda) \quad \forall x \in A, \lambda \in B$$

$$z = \mathcal{L}(x, \lambda_*)$$

$$z = \mathcal{L}(x, \lambda)$$



$$z = \mathcal{L}(x_*, \lambda)$$



# Satz 5.14. Starke Dualität

Die folgenden Aussagen sind äquivalent:

- $(x_*, \lambda_*)$  ist ein Sattelpunkt von  $\mathcal{L}$
- $x_* \in \operatorname{Argmin}_x(F)$ ,  $\lambda_* \in \operatorname{Argmax}_\lambda(G)$  und  $G(\lambda_*) = F(x_*)$

# Beweis

$$\mathcal{L}(x_*, \lambda) \leq \mathcal{L}(x_*, \lambda_*) \leq \mathcal{L}(x, \lambda_*) \quad \forall x \in A, \lambda \in B$$

$$\begin{array}{ccc} \sup_{\lambda \in B} \mathcal{L}(x_*, \lambda) & = & \mathcal{L}(x_*, \lambda_*) = \inf_{x \in A} \mathcal{L}(x, \lambda_*) \\ \parallel & & \parallel \\ F(x_*) & & G(\lambda_*) \end{array}$$

schwache Dualität

$$x_* \in \text{Argmin}_x(F), \lambda_* \in \text{Argmax}_\lambda(G), F(x_*) = G(\lambda_*)$$



# Anwendung der starken Dualität

- Angenommen, das primale und das duale Probleme besitzen optimale Lösungen  $x_*$ ,  $\lambda_*$  und die starke Dualität ist erfüllt
- Man kann  $x_*$  durch die Lösung eines Problems erhalten, die in der Regel einfacher als das primale Problem ist:

$$x_* = \operatorname{argmin}_x \mathcal{L}(x, \lambda_*)$$

- Oft ist das duale Problem einfacher zu lösen, als das primale Problem

# Plan

- Sattelpunkte und Dualität
- Dualität für restringierte Optimierungsprobleme
- Beispiel: Support Vector Machines



# Restringiertes Optimierungsproblem

$$\begin{array}{ll} \text{Minimiere } f(x) \text{ über } x \in A & \text{beliebige Grundmenge} \\ \text{u.d.N. } g(x) \leq 0 & f: A \rightarrow \mathbb{R} \\ h(x) = 0 & g: A \rightarrow \mathbb{R}^{m_U} \\ & h: A \rightarrow \mathbb{R}^{m_G} \end{array}$$

- Dieses Problem lässt sich als primales Problem im Rahmen der Lagrange-Dualität formulieren
- Als **Lagrange-Funktion** bezeichnen wir:  $\leq 0$  für zulässiges  $x$

$$\mathcal{L}(x, \mu, \lambda) := f(x) + \underbrace{\mu^T g(x)}_{\geq 0} + \lambda^T h(x)$$

$$x \in A, (\mu, \lambda) \in B = \mathbb{R}_{\geq 0}^{m_U} \times \mathbb{R}^{m_G}$$



# Das primale Problem


$$\mathcal{L}(x, \mu, \lambda) := f(x) + \mu^T g(x) + \lambda^T h(x)$$

$$F(x) = \sup_{\mu \geq 0, \lambda} \mathcal{L}(x, \mu, \lambda) = \begin{cases} f(x) & h(x) = 0, g(x) \leq 0 \\ \infty & h(x) \neq 0 \text{ oder } g(x) \not\leq 0 \end{cases}$$

Minimiere  $f(x)$  über  $x \in A$

u.d.N.  $g(x) \leq 0$

$h(x) = 0$



$\Leftrightarrow$  Minimiere  $F(x)$  über  $x \in A$

u.d.N.  $F(x) < \infty$

# Das duale Problem

$$\mathcal{L}(x, \mu, \lambda) = f(x) + \mu^T g(x) + \lambda^T h(x)$$

$$G(\mu, \lambda) = \inf_{x \in A} \underbrace{\mathcal{L}(x, \mu, \lambda)}_{\text{linear in } \mu, \lambda} \xrightarrow{\text{Satz 2.12}} \text{konkav}$$

Maximiere  $G(\mu, \lambda)$  über  $(\mu, \lambda) \in \mathbb{R}^{m_U} \times \mathbb{R}^{m_G}$   
u.d.N.  $\mu \geq 0$

*Konkaves Maximierungsproblem  
sogar wenn das primale Problem nicht konvex ist*



# Satz 5.15. Starke Dualität für lineare NB

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $A_U x \geq b_U$

$A_G x = b_G$

$f \in C^1(\mathbb{R}^n)$  konvex

$A_U \in \mathbb{R}^{m_U \times n}, b_U \in \mathbb{R}^{m_U}$

$A_G \in \mathbb{R}^{m_G \times n}, b_G \in \mathbb{R}^{m_G}$

Sei  $x_*$  eine optimale Lösung und  $\mu_*, \lambda_*$  die Lagrange-Multiplikatoren

Dann ist  $(\mu_*, \lambda_*)$  eine optimale Lösung des dualen Problems

Außerdem stimmen die optimalen Funktionswerte des primalen und des dualen Problems überein

*Also gilt die starke Dualität*



# Beweis

*Satz 5.12 (KKT)*  $\mu_* \in \mathbb{R}_+^{m_U}, \lambda_* \in \mathbb{R}^{m_G}$  sind so, dass:

$$\nabla_x \mathcal{L}(x_*, \mu_*, \lambda_*) = 0$$

$\mathcal{L}(\cdot, \mu_*, \lambda_*)$  ist konvex  
Satz 2.20

$$\mathcal{L}(x_*, \mu_*, \lambda_*) \leq \mathcal{L}(x, \mu_*, \lambda_*) \quad \forall x \in \mathbb{R}^n$$

$$\forall \mu \geq 0, \lambda: \quad \mathcal{L}(x_*, \mu, \lambda) = f(x_*) + \underbrace{\mu^T (b_U - A_U x_*)}_{\geq 0} + \underbrace{\lambda^T (b_G - A_G x_*)}_{= 0}$$

$$\leq f(x_*) = \underbrace{\mathcal{L}(x_*, \mu_*, \lambda_*)}_{\mu_{*,i}(b_{U,i} - A_{U,i}x_*) = 0 \text{ (Satz 5.12)}}$$

$\Rightarrow (x_*, \mu_*, \lambda_*)$  ist ein Sattelpunkt von  $\mathcal{L}$   
 $(\mu_*, \lambda_*)$  ist ein optimaler Dualpunkt  
 und die starke Dualität ist erfüllt

Satz 5.14



# Plan


- Lagrange-Dualität
- Dualität für restringierte Optimierungsprobleme
- Beispiel: Support Vector Machines



# Binäre Klassifizierung

- Seien  $x_1, \dots, x_m \in \mathbb{R}^n$  Merkmalsvektoren
- Seien  $t_1, \dots, t_m \in \{1, -1\}$  die zugehörigen Klassen
- Im einfachsten Fall sind die Klassen **linear separierbar**

$$\begin{aligned}w^T x_i - \gamma &> 0 \Leftrightarrow t_i = 1 \\w^T x_i - \gamma &< 0 \Leftrightarrow t_i = -1 \\w &\in \mathbb{R}^n \setminus \{0\}, \gamma \in \mathbb{R}\end{aligned}$$



# Binäre Klassifizierung

$$w^T x_i - \gamma > 0 \Leftrightarrow t_i = 1$$

$$w^T x_i - \gamma < 0 \Leftrightarrow t_i = -1$$


$$w^T x_i - \gamma \geq 1 \Leftrightarrow t_i = 1$$

$$w^T x_i - \gamma \leq -1 \Leftrightarrow t_i = -1$$

Eventuell  $(w, \gamma) := (w/a, \gamma/a)$   
 $a = \min_i |w^T x_i - \gamma|$

- Die Entfernung zwischen den Hyperebenen  $w^T x - \gamma = \pm 1$  ist:

$$2/\|w\|_2$$




# Support Vector Machine

- **SVM:** Wähle  $w, \gamma$  so, dass der Abstand  $2/\|w\|_2$  maximal ist

Minimiere  $\frac{1}{2}\|w\|_2^2$  über  $w, \gamma$

u.d.N.  $t_i(w^T x_i - \gamma) \geq 1, i = 1, \dots, m$



- Sei  $w_*, \gamma_*$  eine optimale Lösung
- $x_k$  heißt **Stützvektor**, falls auf einer Grenzhyperebene liegt:

$$w_*^T x_k - \gamma_* = \pm 1$$



# Aufgabe 5.16. Support Vector Machine

Minimiere  $\frac{1}{2} \|w\|_2^2$  über  $w \in \mathbb{R}^n, \gamma \in \mathbb{R}$

u.d.N.  $t_i(x_i^T w - \gamma) \geq 1, \quad i = 1, \dots, m$

- Der Zulässigkeitsbereich ist nichtleer  $\Leftrightarrow$  die Klassen sind linear separierbar
- Die Klassen sind nichtleer und linear separierbar  $\Rightarrow$  das primale und das duale Probleme haben optimale Lösungen und die starke Dualität ist erfüllt

*Tipp: Verweisen sie auf Satz 5.15*



# Die duale Funktion

- Lagrange-Funktion:

$$\mathcal{L}(w, \gamma; \mu) = \frac{1}{2} w^T w + \sum_{i=1}^m \mu_i (1 - t_i (w^T x_i - \gamma))$$

- Die duale Funktion:

$$G(\mu) = \inf_{w, \gamma} \mathcal{L}(w, \gamma; \mu)$$

- $\mathcal{L}(\cdot, \cdot; \mu)$  ist quadratisch für ein festes  $\mu$ . Optimalitätsbedingungen:

$$\begin{aligned} \nabla_w \mathcal{L}(w, \gamma; \mu) &= w - \sum_{i=1}^m \mu_i t_i x_i = 0 & \Rightarrow & w_* = \sum_{i=1}^m \mu_i t_i x_i \\ \nabla_\gamma \mathcal{L}(w, \gamma; \mu) &= \sum_{i=1}^m \mu_i t_i = 0 & \Rightarrow & \sum_{i=1}^m \mu_i t_i = 0 \end{aligned}$$

Aufgabe 2.21  $\rightarrow$

$$G(\mu) = \begin{cases} \mathcal{L}(w_*, \gamma, \mu) = \sum_{i=1}^m \mu_i - \frac{1}{2} \sum_{i,j=1}^m \mu_i \mu_j t_i t_j x_i^T x_j, & \sum_{i=1}^m \mu_i t_i = 0, \forall \gamma \\ -\infty, & \text{sonst} \end{cases}$$



# Das duale Programm

Maximiere  $\sum_{i=1}^m \mu_i - \frac{1}{2} \sum_{i,j=1}^m \mu_i \mu_j t_i t_j x_i^T x_j$  über  $\mu_1, \dots, \mu_m \in \mathbb{R}$

u.d.N.  $\sum_{i=1}^m \mu_i t_i = 0$

$\mu_1, \dots, \mu_m \geq 0$

- Sei  $w_*, \gamma_*$  eine optimale Lösung des primalen Problems und sei  $\mu_*$  der zugehörige Vektor der Lagrange-Multiplikatoren

*$\mu_*$  ist eine optimale Lösung des dualen Problems nach Satz 5.15*

*$(w_*, \gamma_*) = \operatorname{argmin}_{w, \gamma} \mathcal{L}(w, \gamma, \mu_*)$  nach Satz 5.14  $\Rightarrow w_* = \sum_{i=1}^m \mu_{*,i} t_i x_i$*

- Komplementaritätsbedingung (Satz 5.12):

$\mu_{*,i} (1 - t_i (w_*^T x_i - \gamma_*)) = 0 \Rightarrow \mu_{*,i} > 0$  nur wenn  $x_i$  ein Stützvektor ist

Sei  $x_i$  ein Stützvektor  $\Rightarrow \gamma_* = w_*^T x_i - t_i$



# Klassifizierungsregel

- Sei  $x \in \mathbb{R}^n$ . Dann gehört  $x$  zur Klasse

$$t(x) = \text{sgn}(w_*^T x - \gamma_*)$$

$$w_* = \sum_{i=1}^m \mu_{*,i} t_i x_i$$


$\mu_{*,i} > 0 \Rightarrow x_i$  ist ein Stützvektor

$$t(x) = \text{sgn}\left(\sum_{i: x_i \text{ ist ein Stützvektor}} \mu_{*,i} t_i x_i^T x - \gamma_*\right)$$


*Skalarprodukte mit Stützvektoren bestimmen die Klasse von  $x$*



# Beispiel



$$\varphi: x \mapsto (x, z)$$
$$z = \|x\|_2^2$$



- Die Klassen von  $x_1, \dots, x_m \in \mathbb{R}^2$  sind nicht linear separierbar
- Setze  $y_i = \varphi(x_i) \in \mathbb{R}^3$  mit  $\varphi(x) = (x, \|x\|_2^2)$

*Die Klassen von  $y_1, \dots, y_m$  sind linear separierbar!*



# Klassifizierungsregel

- Wir wenden die SVM auf  $y_1, \dots, y_m$  an  $\Rightarrow$  Klassifizierungsregel

$$t(x) = \text{sgn}\left(\sum_i \mu_{*,i} t_i \varphi(x_i)^T \varphi(x) - \gamma_*\right)$$

- $\varphi$  tritt in die Klassifizierungsregel nur durch ihren **Kernel** ein:

$$K(u, v) = \varphi(u)^T \varphi(v)$$

- Für ein beliebiges  $\varphi: \mathbb{R}^n \rightarrow \mathbb{R}^M$  hat das duale Problem dieselbe Anzahl der Variablen  $m$  und Nebenbedingungen  $m + 1$

*Das primale Problem hat  $M$  Variablen*

*$M = \infty$  ist auch möglich!*



# Kernel-Trick

- Durch eine geeignete Abbildung  $\varphi$  in einen hochdimensionalen Raum kann man die SVM auf nicht linear separierbare Daten anwenden
- $\varphi$  erscheint in der Klassifizierungsregel durch ihren Kernel  $K$

*Man kann direkt nach einen geeigneten Kernel  $K(u, v)$  suchen*

- **Satz von Mercer.**

$$K(u, v) = \varphi(u)^T \varphi(v) \Leftrightarrow \begin{pmatrix} K(x_1, x_1) & \cdots & K(x_1, x_m) \\ \vdots & \ddots & \vdots \\ K(x_m, x_1) & \cdots & K(x_m, x_m) \end{pmatrix} \succcurlyeq 0$$

mit  $\varphi: \mathbb{R}^n \rightarrow \mathbb{R}^M, M \leq \infty$

$$\forall x_1, \dots, x_m, \forall m = 1, 2, \dots$$

# Zusammenfassung

- Sattelpunkte und Dualität
- Dualität für restringierte Optimierungsprobleme
- Beispiel: Support Vektor Machines

# Nächstes Video

- 6a. Lineare Programmierung: Geometrische Grundlagen

