

7a. Nichtlineare Optimierung

Quadratische Programmierung

Optimierung SoSe 2020
Dr. Alexey Agaltsov



Plan

- Beispiel: Portfoliotheorie von Markowitz
- Strategie der aktiven Mengen



Beispiel: Portfolio-Optimierung

n Anlagemöglichkeiten A_1, \dots, A_n

Aktien, Renten, ETFs

Für jede Anlagemöglichkeit A_i seien:

- x_i investierter in A_i Anteil des Vermögens
- Z_i prozentualer Gewinn von A_i (Zufallsvariable)

Portfolio-Gewinn:

$$Y = x_1 Z_1 + \dots + x_n Z_n$$



Zielfunktion

Zwei vernünftige jedoch nicht unabhängige Ziele:


$$\mathbb{E}[Y] \rightarrow \max$$

$$\text{Var}[Y] \rightarrow \min$$

Geeigneter Ausgleich:

$$\mathbb{E}[Y] - \underline{\kappa} \text{Var}[Y] \rightarrow \max$$

Risiko-Toleranz-Parameter



Portfolio-Optimierung

$$\mu_i := \mathbb{E}[Z_i], \quad \mu = (\mu_1, \dots, \mu_n)^T$$

$$V_{ij} := \text{Cov}(Z_i, Z_j), \quad \mathbf{V} = (V_{ij})$$

Erinnerung. $\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)]$
 $= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$

$$\text{Var}[X] = \text{Cov}(X, X)$$

Lemma 7.1. 1. $\mathbb{E}[Y] = \mu^T x, \quad x = (x_1, \dots, x_n)^T$
2. $\text{Var}[Y] = x^T \mathbf{V} x$




Beweis: zu 1

$$\begin{aligned}\mathbb{E}[Y] &= \mathbb{E}[x_1 Z_1 + \cdots + x_n Z_n] \\ &= x_1 \mathbb{E}[Z_1] + \cdots + x_n \mathbb{E}[Z_n] \\ &= x_1 \mu_1 + \cdots + x_n \mu_n = \mu^T x\end{aligned}$$



Beweis: zu 2

$$\begin{aligned} \text{Var}[Y] &= \mathbb{E}[Y^2] - \mathbb{E}[Y]^2 \\ &= \mathbb{E}[(x_1 Z_1 + \cdots + x_n Z_n)^2] - \mathbb{E}[x_1 Z_1 + \cdots + x_n Z_n]^2 \\ &= \sum_{i,j} x_i x_j \mathbb{E}[Z_i Z_j] - \sum_{i,j} x_i x_j \mathbb{E}[Z_i] \mathbb{E}[Z_j] \\ &= \sum_{i,j} x_i x_j \underbrace{\text{Cov}[Z_i, Z_j]}_{V_{ij}} = x^T V x \end{aligned}$$



Effiziente Portfolios

Portfolio x_* ist **effizient** falls die folgenden äquivalenten Aussagen gelten:

Es hat die minimale Renditevarianz für
gegebene erwartete Rendite

$$\begin{aligned} &\text{Minimiere } x^T V x \text{ über } x \in \mathbb{R}^n \\ &\text{u.d.N. } \mu^T x \geq \bar{\mu} \\ &\mathbf{1}^T x = 1 \end{aligned}$$

*voll investiertes
Portfolio*

Es liefert die maximale erwartete Rendite für
gegebene Renditevarianz

$$\begin{aligned} &\text{Maximiere } \mu^T x \text{ über } x \in \mathbb{R}^n \\ &\text{u.d.N. } x^T V x \leq \bar{\sigma}^2 \\ &\mathbf{1}^T x = 1 \end{aligned}$$

$$\begin{aligned} &\text{Maximiere } \mu^T x - \frac{\kappa}{2} x^T V x \\ &\text{u.d.N. } \mathbf{1}^T x = 1 \end{aligned}$$

Risiko-Toleranz-Parameter $\kappa > 0$



Minimum-Varianz-Portfolio

- Für $\kappa \rightarrow +\infty$ erhalten wir das Minimum-Varianz-Portfolio:

$$\begin{aligned} &\text{Minimiere } \frac{1}{2}x^T V x \\ &\text{u.d.N. } \mathbf{1}^T x = 1 \end{aligned}$$

$$\mathcal{L}(x, \lambda) = \frac{1}{2}x^T V x + \lambda(1 - \mathbf{1}^T x)$$

$$\begin{aligned} \nabla_x \mathcal{L}(x, \lambda) &= Vx - \lambda \mathbf{1} = 0 \\ \nabla_\lambda \mathcal{L}(x, \lambda) &= 1 - \mathbf{1}^T x = 0 \end{aligned} \quad \Rightarrow \quad \begin{aligned} x_* &= \lambda_* V^{-1} \mathbf{1}, \\ \lambda_* &= \frac{1}{\mathbf{1}^T V^{-1} \mathbf{1}} \end{aligned}$$

$$x_* = \frac{V^{-1} \mathbf{1}}{\mathbf{1}^T V^{-1} \mathbf{1}}$$



Effiziente Portfolios

$$\begin{aligned} &\text{Maximiere } \mu^T x - \frac{\kappa}{2} x^T V x \\ &\text{u.d.N. } \mathbf{1}^T x = 1 \end{aligned}$$

$$\mathcal{L}(x, \lambda) = \mu^T x - \frac{\kappa}{2} x^T V x + \lambda(1 - \mathbf{1}^T x)$$

$$\begin{aligned} \nabla_x \mathcal{L}(x, \lambda) &= \mu - \kappa V x - \lambda \mathbf{1} = 0 & x_* &= \frac{1}{\kappa} V^{-1} (\mu - \lambda_* \mathbf{1}) \\ \nabla_\lambda \mathcal{L}(x, \lambda) &= 1 - \mathbf{1}^T x = 0 & \Rightarrow \lambda_* &= \frac{\mathbf{1}^T V^{-1} \mu - \kappa}{\mathbf{1}^T V^{-1} \mathbf{1}} \end{aligned}$$

⇒ **Zwei-Fonds-Theorem:**

$$x_* = \underbrace{\alpha \frac{V^{-1} \mu}{\mathbf{1}^T V^{-1} \mu}}_{\text{Maximum-Sharpe-Ratio-Portfolio}} + (1 - \alpha) \underbrace{\frac{V^{-1} \mathbf{1}}{\mathbf{1}^T V^{-1} \mathbf{1}}}_{\text{Minimum-Varianz-Portfolio}}, \quad \alpha = \frac{1}{\kappa} \mathbf{1}^T V^{-1} \mu$$

Maximum-Sharpe-Ratio-Portfolio

Minimum-Varianz-Portfolio



Maximum-Sharpe-Ratio-Portfolio

Maximiere $\frac{\mu^T x}{\sqrt{x^T V x}}$ über $x \in \mathbb{R}^n$ \swarrow Sharpe-Ratio

*Risikoadjustierte
Performance-Maß*

$\mathbf{1}^T x = 1$

$x := \frac{z}{\gamma}$ mit $z^T \mu = 1$ und $\gamma > 0$

Minimiere $z^T V z$ über $z \in \mathbb{R}^n, \gamma \in \mathbb{R}$

u.d.N. $\mathbf{1}^T z = \gamma$
 $\mu^T z = 1$
 $\gamma > 0$

$\Rightarrow \gamma_* = \mathbf{1}^T z_*, \quad z_* = \frac{V^{-1} \mu}{\mu^T V^{-1} \mu}$

$x_* = \frac{V^{-1} \mu}{\mathbf{1}^T V^{-1} \mu}$



Plan

- Beispiel: Portfoliotheorie von Markowitz
- Strategie der aktiven Mengen



Quadratisches Programm

Minimiere $f(x) = \frac{1}{2}x^T Qx - c^T x$, $Q \in \mathbb{S}_{>}^n$

u.d.N. $A_U x \leq b_U$

$A_G x = b_G$

- Satz 5.12: x_* ist eine optimale Lösung $\Leftrightarrow \exists \mu_* \in \mathbb{R}^{m_U}, \lambda_* \in \mathbb{R}^{m_G}$ sodass:

$$Qx_* + A_U^T \mu_* + A_G^T \lambda_* = c$$

$$A_U x_* \leq b_U, \quad A_G x_* = b_G \quad \text{KKT-Bedingungen}$$

$$\mu_* \geq 0$$

$$(b_U - A_U x_*)^T \mu_* = 0$$

- Man kann x_* durch die Lösung dieses Systems finden



Aktive und inaktive Mengen

- x_* ist eine optimale Lösung $\Leftrightarrow \exists \mathcal{A}_* \subseteq \{1, \dots, m_U\}, \mu_* \in \mathbb{R}^{m_U}, \lambda_* \in \mathbb{R}^{m_G}$:

$$Qx_* + A_U[\mathcal{A}_*, :]^T \mu_*[\mathcal{A}_*] + A_G^T \lambda_* = c$$

$$A_U[\mathcal{A}_*, :]x_* = b_U[\mathcal{A}_*], \quad A_G x_* = b_G$$

$$\mathcal{A}_U[\mathcal{A}_*^c, :]x_* \leq b_U[\mathcal{A}_*^c]$$

$$\mu_*[\mathcal{A}_*] \geq 0, \quad \mu_*[\mathcal{A}_*^c] = 0$$

- Also ist $\mathcal{A}_* \subseteq \mathcal{A}(x_*)$, wobei $\mathcal{A}(x_*)$ ist die aktive Menge bei x_* :

$$\mathcal{A}(x_*) = \{i: A_U[i, :]x_* = b_U[i]\}$$



Einfache Strategie

- x_* ist eine optimale Lösung $\Leftrightarrow \exists \mathcal{A}_* \subseteq \{1, \dots, m_U\}, \mu_* \in \mathbb{R}^{m_U}, \lambda_* \in \mathbb{R}^{m_G}$:

$$\begin{bmatrix} Q & A_U[\mathcal{A}_*, :]^T & A_G^T \\ A_U[\mathcal{A}_*, ;] & 0 & 0 \\ A_G & 0 & 0 \end{bmatrix} \begin{bmatrix} x_* \\ \mu_*[\mathcal{A}_*] \\ \lambda_* \end{bmatrix} = \begin{bmatrix} c \\ b_U[\mathcal{A}_*] \\ b_G \end{bmatrix} \quad \textit{Sattelpunktgleichung}$$

$$A_U[\mathcal{A}_*^c, :]x_* \leq b_U[\mathcal{A}_*^c]$$

$$\mu_*[\mathcal{A}_*] \geq 0, \mu_*[\mathcal{A}_*^c] = 0$$



Einfache Strategie

- x_* ist eine optimale Lösung $\Leftrightarrow \exists \mathcal{A}_* \subseteq \{1, \dots, m_U\}, \mu \in \mathbb{R}^{m_U}, \lambda \in \mathbb{R}^{m_G}$:

$$\begin{bmatrix} Q & A_U[\mathcal{A}_*, :]^T & A_G^T \\ A_U[\mathcal{A}_*, ;] & 0 & 0 \\ A_G & 0 & 0 \end{bmatrix} \begin{bmatrix} x_* \\ \mu_*[\mathcal{A}_*] \\ \lambda_* \end{bmatrix} = \begin{bmatrix} c \\ b_U[\mathcal{A}_*] \\ b_G \end{bmatrix} \quad \text{Sattelpunktgleichung}$$

$$\begin{aligned} A_U[\mathcal{A}_*^c, :]x_* &\leq b_U[\mathcal{A}_*^c] \\ \mu_*[\mathcal{A}_*] &\geq 0, \mu_*[\mathcal{A}_*^c] = 0 \end{aligned}$$

- Einfache Strategie:
 1. Wähle $\mathcal{A} \subseteq \{1, \dots, m_U\}$ und bestimme $x, \mu[\mathcal{A}], \lambda$ als eine Lösung der Sattelpunktgleichung
 2. Ist $A_U[\mathcal{A}^c, :]x \leq b_U[\mathcal{A}^c]$ und $\mu[\mathcal{A}] \geq 0$, so ist x optimal



Sattelpunktgleichung

$$\begin{bmatrix} Q & A_U[\mathcal{A}_*,:]^T & A_G^T \\ A_U[\mathcal{A}_*,:] & 0 & 0 \\ A_G & 0 & 0 \end{bmatrix} \begin{bmatrix} x_* \\ \mu_*[\mathcal{A}_*] \\ \lambda_* \end{bmatrix} = \begin{bmatrix} c \\ b_U[\mathcal{A}_*] \\ b_G \end{bmatrix}$$

- Hat $\begin{bmatrix} A_U[\mathcal{A},:] \\ A_G \end{bmatrix}$ vollen Zeilenrang und $Q \in \mathbb{S}_{>}^n$, so gibt es eine eindeutige Lösung nach Aufgabe 5.6

- In diesem Fall gibt es eine analytische Formel für die optimale Lösung

$$x_* = Q^{-1}c + Q^{-1}A_U[\mathcal{A}_*,:]^T \mu_*[\mathcal{A}_*] + Q^{-1}A_G^T \lambda_*$$

Setze x_ in 2. und 3. Gleichungen ein um $\mu_*[\mathcal{A}_*], \lambda_*$ zu finden*



Strategie der aktiven Mengen (SAM)

- Sei \mathcal{A}_k eine aktuelle Approximation an \mathcal{A}_*
- Sei x_k ein zulässiger Punkt mit $\mathcal{A}_k \subseteq \mathcal{A}(x_k)$:

$$A_U[\mathcal{A}_k, :]x_k = b_U[\mathcal{A}_k]$$

$$A_U[\mathcal{A}_k^c, :]x_k \leq b_U[\mathcal{A}_k^c]$$

$$A_G x_k = b_G$$

- Der SAM-Schritt findet eine bessere Approximation \mathcal{A}_{k+1} an \mathcal{A}_* und eine bessere Approximation x_{k+1} an x_* mit $\mathcal{A}_{k+1} \subseteq \mathcal{A}(x_{k+1})$



Neue Näherungslösung

$$\begin{bmatrix} Q & A_U[\mathcal{A}_*,:]^T & A_G^T \\ A_U[\mathcal{A}_*,:] & 0 & 0 \\ A_G & 0 & 0 \end{bmatrix} \begin{bmatrix} x_* \\ \mu_*[\mathcal{A}_*] \\ \lambda_* \end{bmatrix} = \begin{bmatrix} c \\ b_U[\mathcal{A}_*] \\ b_G \end{bmatrix}$$

$$\begin{bmatrix} Q & A_U[\mathcal{A}_k,:]^T & A_G^T \\ A_U[\mathcal{A}_k,:] & 0 & 0 \\ A_G & 0 & 0 \end{bmatrix} \begin{bmatrix} x_{k+1} \\ \mu_{k+1}[\mathcal{A}_k] \\ \lambda_{k+1} \end{bmatrix} = \begin{bmatrix} c \\ b_U[\mathcal{A}_k] \\ b_G \end{bmatrix}$$

$$\begin{bmatrix} Q & A_U[\mathcal{A}_k,:]^T & A_G^T \\ A_U[\mathcal{A}_k,:] & 0 & 0 \\ A_G & 0 & 0 \end{bmatrix} \begin{bmatrix} p_k \\ \mu_{k+1}[\mathcal{A}_k] \\ \lambda_{k+1} \end{bmatrix} = \begin{bmatrix} c - Qx_k \\ 0 \\ 0 \end{bmatrix}$$

$$\begin{aligned} p_k &:= x_{k+1} - x_k \\ A_U[\mathcal{A}_k,:]x_k &= b_U[\mathcal{A}_k] \\ A_Gx_k &= b_G \end{aligned}$$



Optimalitätsbedingung

- Ist $p_k = 0$, so ist x_k nach Satz 5.5 eine optimale Lösung von:

$$\text{Minimiere } \frac{1}{2}x^T Qx - c^T x \text{ über } x \in \mathbb{R}^n$$

$$\text{u.d.N. } A_U[\mathcal{A}_k, :]x_k = b_U[\mathcal{A}_k], \quad A_G x_k = b_G$$

- Ist zusätzlich $\mu_{k+1}[\mathcal{A}_k] \geq 0$, so ist x_k nach Satz 5.12 eine optimale Lösung von:

$$\text{Minimiere } \frac{1}{2}x^T Qx - c^T x \text{ über } x \in \mathbb{R}^n$$

$$\text{u.d.N. } A_U[\mathcal{A}_k, :]x_k \leq b_U[\mathcal{A}_k], \quad A_G x_k = b_G$$

- Nach Annahme $A_U[\mathcal{A}_k^c, :]x_k \leq b_U[\mathcal{A}_k^c]$, also ist x_k eine optimale Lösung von:

$$\text{Minimiere } \frac{1}{2}x^T Qx - c^T x \text{ über } x \in \mathbb{R}^n$$

$$\text{u.d.N. } A_U x_k \leq b_U, \quad A_G x_k = b_G$$

\Rightarrow STOP



Deaktivierungsschritt

- Ist $p_k = 0$, so ist x_k eine optimale Lösung von:

Minimiere $\frac{1}{2}x^T Qx - c^T x$ über $x \in \mathbb{R}^n$

$$\text{u.d.N. } A_U[\mathcal{A}_k, :]x_k = b_U[\mathcal{A}_k]$$

$$A_G x_k = b_G$$

- Gibt es ein $k_* \in \mathcal{A}_k$ mit $\mu_{k+1}[k_*] < 0$, so steigt der optimale Funktionswert im obigen Problem mit $b_U[k_*]$ nach Satz 5.4
- Neue Approximation an \mathcal{A}_* :

$$\mathcal{A}_{k+1} = \mathcal{A}_k \setminus \{k_*\} \quad \text{Deaktivierungsschritt}$$



Lemma 7.2: Abstiegsrichtung

Angenommen, $p_k \neq 0$. Dann gelten die folgenden Aussagen:

- p_k erfüllt die Bedingungen:

$$-\nabla f(x_k)^T p_k = p_k^T Q p_k > 0 \quad \text{Abstiegsrichtung}$$

$$A_U[\mathcal{A}_k, :] p_k = 0$$

$$A_G p_k = 0$$

- $g(\alpha) = f(x_k + \alpha p_k)$ eine quadratische Funktion und $\alpha = 1$ ist ihr globales Minimum
- Also ist $g(\alpha)$ monoton fallend für $\alpha \in [0,1]$



Beweis: zu 1

$$\begin{bmatrix} Q & A_U[\mathcal{A}_k, :]^T & A_G^T \\ A_U[\mathcal{A}_k, ;] & 0 & 0 \\ A_G & 0 & 0 \end{bmatrix} \begin{bmatrix} p_k \\ \mu_{k+1}[\mathcal{A}_k] \\ \lambda_{k+1} \end{bmatrix} = \begin{bmatrix} \overline{-\nabla f(x_k)} \\ 0 \\ 0 \end{bmatrix} \quad \begin{array}{l} | Z_1 \\ | Z_2 \\ | Z_3 \end{array}$$

$$Z_2: A_U[\mathcal{A}_k, :]p_k = 0$$

$$Z_3: A_G p_k = 0$$

$$= 0$$

$$= 0$$

$$p_k^T Z_1: \underbrace{p_k^T Q p_k}_{> 0} + \overbrace{(A_U[\mathcal{A}_k, :]p_k)^T \mu_{k+1}[\mathcal{A}_k]}^{= 0} + \overbrace{(A_G p_k)^T \lambda_{k+1}}^{= 0} = -\nabla f(x_k)^T p_k$$



Beweis: zu 2 und 3

$$f(x) = \frac{1}{2}x^T Qx - c^T x$$

$\Rightarrow g(\alpha) = f(x_k + \alpha p_k)$ ist ebenfalls quadratisch

$$\begin{aligned} g'(1) &= \nabla f(x_k + p_k)^T p_k \\ &= (Q(x_k + p_k) - c)^T p_k \\ &= p_k^T Q p_k + (Qx_k - c)^T p_k \\ &= -\nabla f(x_k)^T p_k + \nabla f(x_k)^T p_k = 0 \end{aligned}$$

$\alpha = 1$ ist das globale Minimum von g

g fällt auf $[0,1]$



Neue Approximation

$$x(\alpha) := x_k + \alpha p_k \quad \text{Lemma 7.2}$$

$$A_U[\mathcal{A}_k, :]x(\alpha) = b_U[\mathcal{A}_k], \quad A_G x(\alpha) = b_G$$

$f(x(\alpha))$ fällt auf $[0,1]$ und $\alpha = 1$ ist das Minimum

$$A_U[\mathcal{A}_k^c, :]x(\alpha) \leq b_U[\mathcal{A}_k^c] \iff \alpha A_U[\mathcal{A}_k^c, :]p_k \leq b_U[\mathcal{A}_k^c] - A_U[\mathcal{A}_k^c, :]x_k$$

$$\iff \alpha \leq \min \left\{ \frac{b_U[i] - A_U[i, :]x_k}{A_U[i]p_k} : A_U[i]p_k > 0, i \in \mathcal{A}_k^c \right\} = \alpha_*$$

- Neue Approximation:

$$x_{k+1} = x_k + \alpha_k p_k$$

$$\alpha_k := \min\{\alpha_*, 1\} \quad \text{Schrittweitenregel}$$



Aktivierungsschritt

- Angenommen:

$$\alpha_k = \min \left\{ \frac{b_U[i] - A_U[i, :]x_k}{A_U[i, :]p_k} : A_U[i, :]p_k > 0, i \in \mathcal{A}_k^c \right\} < 1$$

- Wir nennen $i_* \in \mathcal{A}_k^c$ **blockierender Index** falls

$$\alpha_k = \alpha_k(i_*) := \frac{b_U[i_*] - A_U[i_*, :]x_k}{A_U[i_*, :]p_k} \Rightarrow A_U[i_*, :]x_{k+1} = b_U[i_*]$$

- Neue Approximation an \mathcal{A}_* :

$$\mathcal{A}_{k+1} = \mathcal{A}_k \cup \{i_*\}$$



Strategie der aktiven Mengen

1. *Initialisierung*: Zulässiger Startwert x_0 , Menge \mathcal{A}_0 sd. $A_U[\mathcal{A}_0, :]x_0 = b_U[\mathcal{A}_0]$
2. **for** $k = 0, 1, 2, \dots$ **do**:
3. bestimme $p_k, \mu_{k+1}[\mathcal{A}_k]$ aus der Sattelpunktgleichung
4. **if** $p_k = 0$ **then**:
5. **if** $\mu_{k+1}[\mathcal{A}_k] \geq 0$ **then** STOP(„Optimale Lösung“)
6. $j_* = \operatorname{argmin}_{i \in \mathcal{A}} \mu_{k+1}[j]$, $\mathcal{A}_{k+1} = \mathcal{A}_k \setminus \{j_*\}$, $x_{k+1} = x_k$ *Deaktivierungsschritt*



Strategie der aktiven Mengen

1. *Initialisierung*: Zulässiger Startwert x_0 , Menge \mathcal{A}_0 sd. $A_U[\mathcal{A}_0, :]x_0 = b_U[\mathcal{A}_0]$
2. **for** $k = 0, 1, 2, \dots$ **do**:
3. bestimme $p_k, \mu_{k+1}[\mathcal{A}_k]$ aus der Sattelpunktgleichung
4. **if** $p_k = 0$ **then**:
5. **if** $\mu_{k+1}[\mathcal{A}_k] \geq 0$ **then** STOP(„Optimale Lösung“)
6. $j_* = \operatorname{argmin}_{i \in \mathcal{A}} \mu_{k+1}[j]$, $\mathcal{A}_{k+1} = \mathcal{A}_k \setminus \{j_*\}$, $x_{k+1} = x_k$ *Deaktivierungsschritt*
7. **else**:
8. bestimme α_k mithilfe der Schrittweitenregel und setze $x_{k+1} = x_k + \alpha_k p_k$
9. **if** $\alpha_k = \alpha_k(i_*) < 1$ **then** $\mathcal{A}_{k+1} = \mathcal{A}_k \cup \{i_*\}$ **else** $\mathcal{A}_{k+1} = \mathcal{A}_k$
10. **end for** *Aktivierungsschritt*



Satz 7.3. Durchführbarkeit

$$H_k := \begin{bmatrix} Q & A_U[\mathcal{A}_k, :]^T & A_G^T \\ A_U[\mathcal{A}_k, ;] & 0 & 0 \\ A_G & 0 & 0 \end{bmatrix} \quad Q \in \mathbb{S}_{>}^n$$

Angenommen:

- $\text{rang} \begin{bmatrix} A_U[\mathcal{A}_0, :] \\ A_G \end{bmatrix} = |\mathcal{A}_0| + m_G$
- x_k mit $k \geq 0$ ist nicht optimal

Dann ist H_k regulär und somit ist x_{k+1} wohldefiniert



Beweis

Behauptung: $\text{rang} \begin{bmatrix} A_U[\mathcal{A}_k, :] \\ A_G \end{bmatrix} = |\mathcal{A}_k| + m_G \Rightarrow H_k \text{ ist regulär}$

$$H_k = \begin{bmatrix} \overset{\text{positiv definit}}{Q} & A_U[\mathcal{A}_k, :]^T & A_G^T \\ \boxed{A_U[\mathcal{A}_k, ;]} & 0 & 0 \\ A_G & 0 & 0 \end{bmatrix}$$

Voller Zeilenrang

Aufgabe 5.6

H_k ist regulär



Beweis

$$\text{Behauptung: } \begin{cases} \text{rang} \begin{bmatrix} A_U[\mathcal{A}_k, :] \\ A_G \end{bmatrix} = |\mathcal{A}_k| + m_G \\ x_k \text{ ist nicht optimal} \end{cases} \Rightarrow \text{rang} \begin{bmatrix} A_U[\mathcal{A}_{k+1}, :] \\ A_G \end{bmatrix} = |\mathcal{A}_{k+1}| + m_G$$

1. Fall: $p_k = 0, \mu_{k+1}[\mathcal{A}_k] \geq 0 \Rightarrow x_k$ ist optimal (Widerspruch zur Annahme)

2. Fall: $p_k = 0, \mu_{k+1}[\mathcal{A}_k] \not\geq 0$ oder $p_k \neq 0, \alpha_k = 1 \Rightarrow \mathcal{A}_{k+1} \subseteq \mathcal{A}_k \Rightarrow$ Behauptung



Beweis

Behauptung: $\begin{cases} \text{rang} \begin{bmatrix} A_U[\mathcal{A}_k, :] \\ A_G \end{bmatrix} = |\mathcal{A}_k| + m_G \\ x_k \text{ ist nicht optimal} \end{cases} \Rightarrow \text{rang} \begin{bmatrix} A_U[\mathcal{A}_{k+1}, :] \\ A_G \end{bmatrix} = |\mathcal{A}_{k+1}| + m_G$

1. Fall: $p_k = 0, \mu_{k+1}[\mathcal{A}_k] \geq 0 \Rightarrow x_k$ ist optimal (Widerspruch zur Annahme)
2. Fall: $p_k = 0, \mu_{k+1}[\mathcal{A}_k] \not\geq 0$ oder $p_k \neq 0, \alpha_k = 1 \Rightarrow \mathcal{A}_{k+1} \subseteq \mathcal{A}_k \Rightarrow$ Behauptung
3. Fall: $p_k \neq 0, \alpha_k = \alpha_k(i_*) < 1 \Rightarrow A_{k+1} = A_k \cup \{i_*\}$

Angenommen, $\exists d, q$ so, dass: $A_U[i_*, :] = d^T A_U[\mathcal{A}_k, :] + q^T A_G$

$$A_U[i_*, :] p_k = 0 \quad \leftarrow \text{Lemma 7.2}$$

Widerspruch zur Definition von i_*



Beispiel

Minimiere $\frac{1}{2}(x-1)^2 + \frac{1}{2}(y-2.5)^2$


u.d.N. $-x + 2y \leq 2$ (1)

$x + 2y \leq 6$ (2)

$x - 2y \leq 2$ (3)

$-y \leq 0$ (4)

$-x \leq 0$ (5)




$$x_0 = \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \quad \mathcal{A}_0 = \{3,4\}$$

$$\mathcal{F} := \{x: x \text{ erfüllt alle NB}\}$$





$$\mathcal{M}_k := \{x: x \text{ erfüllt die NB } \mathcal{A}_k \text{ mit Gleichheit}\}$$








Strategie der aktiven Mengen









Strategie der aktiven Mengen



Strategie der aktiven Mengen



Strategie der aktiven Mengen



Zusammenfassung

- Beispiel: Portfoliotheorie von Markowitz
- Strategie der aktiven Mengen



Zusammenfassung

- 7b. Nichtlineare Optimierung: Optimalitätsbedingungen

