

# 7b. Nichtlineare Optimierung

## Optimalitätsbedingungen

Optimierung SoSe 2020

Dr. Alexey Agaltsov



# Plan

- Optimalitätsbedingungen
- Regularitätsvoraussetzungen
- Dualität für konvexe Programme



# Mathematisches Programm

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$


$$\begin{aligned} \text{u.d.N. } g_i(x) &\leq 0, \quad i = 1, \dots, m_U & f, g_i, h_i &\in C^1(\mathbb{R}^n) \\ h_i(x) &= 0, \quad i = 1, \dots, m_G \end{aligned}$$

- Setze  $\mathcal{F} = \{x \in \mathbb{R}^n : g_i(x) \leq 0 \quad i = 1, \dots, m_U, h_i(x) = 0 \quad i = 1, \dots, m_G\}$
- Angenommen,  $x_*$  ist eine optimale Lösung
- Wie kann man  $x_*$  charakterisieren und bestimmen?



# Tangentialkegel

- $d \in \mathbb{R}^n$  heißt **Tangentialvektor** zu  $\mathcal{F}$  in  $x_*$  falls:  
$$\exists (x_k) \subseteq \mathcal{F} \text{ mit } x_k = x_* + d/k + o(1/k), \quad k \rightarrow \infty$$
- Tangentialvektoren bilden **Tangentialkegel**  $\mathcal{T}_{\mathcal{F}}(x_*)$



## Lemma 7.4. Optimalitätsbedingung

Sei  $x_*$  ein lokales Minimum von  $f$  auf  $\mathcal{F}$ . Dann  $-\nabla f(x_*)^T d \leq 0 \quad \forall d \in \mathcal{T}_{\mathcal{F}}(x_*)$

*Beweis.*

Sei  $d \in \mathcal{T}_{\mathcal{F}}(x_*)$  und  $x_k = x_* + d/k + o(1/k) \in \mathcal{F}$

$$f(x_*) \leq f(x_k) \quad \text{für alle } k \geq K$$

$$= f(x_* + d/k + o(1/k))$$


subtrahiere  $f(x_*)$

$$= f(x_*) + \nabla f(x_*)^T d/k + o(1/k)$$

multipliziere mit  $k$

$$k \rightarrow \infty$$

$$-\nabla f(x_*)^T d \leq 0$$



# Linearisierter Tangentialkegel

$$\mathcal{A}(x_*) = \{i = 1, \dots, m_U: g_i(x_*) = 0\} \quad \text{Aktive Menge bei } x_*$$

- Sei  $d \in \mathcal{T}_{\mathcal{F}}(x_*)$  sodass  $\exists(x_k) \in \mathcal{F}$  mit  $x_k = x_* + d/k + o(1/k)$

$$\begin{array}{lcl} h_i(x_k) & = & h_i(x_*) + \nabla h_i(x_*)^T d/k + o(1/k), \quad i = 1, \dots, m_G \Rightarrow \nabla h_i(x_*)^T d = 0 \\ = 0 & & = 0 \end{array}$$



# Linearisierter Tangentialkegel

$$\mathcal{A}(x_*) = \{i = 1, \dots, m_U: g_i(x_*) = 0\} \quad \text{Aktive Menge bei } x_*$$

- Sei  $d \in \mathcal{T}_{\mathcal{F}}(x_*)$  sodass  $\exists (x_k) \in \mathcal{F}$  mit  $x_k = x_* + d/k + o(1/k)$

$$\begin{array}{ll} h_i(x_k) = h_i(x_*) + \nabla h_i(x_*)^T d/k + o(1/k), & i = 1, \dots, m_G \Rightarrow \nabla h_i(x_*)^T d = 0 \\ = 0 & = 0 \end{array}$$

$$\begin{array}{ll} g_i(x_k) = g_i(x_*) + \nabla g_i(x_*)^T d/k + o(1/k), & i \in \mathcal{A}(x_*) \Rightarrow \nabla g_i(x_*)^T d \leq 0 \\ \leq 0 & = 0 \end{array}$$

- Also  $\mathcal{T}_{\mathcal{F}}(x_*) \subseteq \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$ , wobei  $\mathcal{T}_{\mathcal{F}}^{lin}(x_*)$  ist **der linearisierte Tangentialkegel**:

$$\mathcal{T}_{\mathcal{F}}^{lin}(x_*) = \{d: \nabla g_i(x_*)^T d \leq 0 \ i \in \mathcal{A}(x_*), \nabla h_i(x_*)^T d = 0 \ i = 1, \dots, m_G\}$$



# Abadie Constraint Qualification (Abadie CQ)

- Sei die *Abadie Constraint Qualification*  $\mathcal{T}_{\mathcal{F}}(x_*) = \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$  erfüllt Lemma 7.4

$-\nabla f(x_*)^T d \leq 0$  für alle  $d$  mit  $\nabla g_i(x_*)^T d \leq 0, i \in \mathcal{A}(x_*), \nabla h_i(x_*)^T d = 0, i = 1, \dots, m_G$

Farkas Lemma

$$-\nabla f(x_*) = \sum_{i \in \mathcal{A}(x_*)} \underbrace{\mu_i^*}_{\geq 0} \nabla g_i(x_*) + \sum_{i=1}^{m_G} \underbrace{\eta_i^*}_{\geq 0} \nabla h_i(x_*) + \sum_{i=1}^{m_G} \underbrace{\theta_i^*}_{\geq 0} (-\nabla h_i(x_*))$$





# Abadie Constraint Qualification (Abadie CQ)

- Sei die *Abadie Constraint Qualification*  $\mathcal{T}_{\mathcal{F}}(x_*) = \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$  erfüllt Lemma 7.4

$-\nabla f(x_*)^T d \leq 0$  für alle  $d$  mit  $\nabla g_i(x_*)^T d \leq 0, i \in \mathcal{A}(x_*), \nabla h_i(x_*)^T d = 0, i = 1, \dots, m_G$

Farkas Lemma

$$-\nabla f(x_*) = \sum_{i \in \mathcal{A}(x_*)} \underbrace{\mu_i^*}_{\geq 0} \nabla g_i(x_*) + \sum_{i=1}^{m_G} \underbrace{\eta_i^*}_{\geq 0} \nabla h_i(x_*) + \sum_{i=1}^{m_G} \underbrace{\theta_i^*}_{\geq 0} (-\nabla h_i(x_*))$$

$$\begin{aligned} \lambda_i^* &:= \eta_i^* - \theta_i^* \\ \mu_i^* &:= 0 \text{ für } i \in \mathcal{A}(x_*)^c \end{aligned}$$

$$\nabla f(x_*) + \sum_{i=1}^{m_U} \underbrace{\mu_i^*}_{\geq 0} \nabla g_i(x_*) + \sum_{i=1}^{m_G} \underbrace{\lambda_i^*}_{\in \mathbb{R}} \nabla h_i(x_*),$$

$$\mu_i^* g_i(x_*) = 0, \quad i = 1, \dots, m_U \quad \text{Komplementaritätsbedingung}$$



# KKT-Punkt

- Wir bezeichnen  $(x, \mu, \lambda) \in \mathbb{R}^{n \times m_U \times m_G}$  als **KKT-Punkt** (nach Karush-Kuhn-Tucker) falls die **KKT-Bedingungen** gelten:

$$\nabla f(x) + \sum_{i=1}^{m_U} \mu_i \nabla g_i(x) + \sum_{i=1}^{m_G} \lambda_i \nabla h_i(x) = 0 \quad \nabla_x \mathcal{L}(x, \mu, \lambda) = 0$$

$$g_i(x) \leq 0, \quad h_i(x) = 0 \quad \forall i$$

$$\mu \geq 0$$

$$\mu_i g_i(x) = 0, \quad i = 1, \dots, m_U$$

$$\mathcal{L}(x, \mu, \lambda) = f(x) + \sum_{i=1}^{m_U} \mu_i g_i(x) + \sum_{i=1}^{m_G} \lambda_i h_i(x)$$

Lagrange-Funktion



# Satz 7.5. Optimalitätsbedingungen

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

$$\begin{aligned} \text{u.d.N. } g_i(x) &\leq 0, \quad i = 1, \dots, m_U & f, g_i, h_i &\in C^1(\mathbb{R}^n) \\ h_i(x) &= 0, \quad i = 1, \dots, m_G \end{aligned}$$

- Sei  $x_*$  ein lokales Minimum und sei die Abadie CQ bei  $x_*$  erfüllt:

$$\mathcal{T}_{\mathcal{F}}(x_*) = \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$$

- Dann gibt es  $(\mu_*, \lambda_*)$  sodass  $(x_*, \mu_*, \lambda_*)$  ein KKT-Punkt ist

*Lagrange-Multiplikatoren*



# Beispiel 7.6. Problem ohne Lagrange-Multiplikatoren

Minimiere  $f(x) = x_1 + x_2$


$$\text{u.d.N. } h_1(x) = (x_1 - 1)^2 + x_2^2 - 1 = 0$$

$$h_2(x) = (x_1 - 2)^2 + x_2^2 - 4 = 0$$

- Es gibt keine  $\lambda_1, \lambda_2$  so dass:

$$\nabla f(0) + \lambda_1 \nabla h_1(0) + \lambda_2 \nabla h_2(0) = 0$$

- $\mathcal{T}_{\mathcal{F}}(0) = \{0\} \neq \mathcal{T}_{\mathcal{F}}^{lin}(0) = \{0\} \times \mathbb{R}$



# Plan

- Optimalitätsbedingungen
- Regularitätsvoraussetzungen
- Dualität für konvexe Programme



# Regularitätsvoraussetzungen

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

$$\begin{aligned} \text{u.d.N. } g_i(x) &\leq 0, \quad i = 1, \dots, m_U & f, g_i, h_i &\in C^1(\mathbb{R}^n) \\ h_i(x) &= 0, \quad i = 1, \dots, m_G \end{aligned}$$

- Sei  $x_*$  eine optimale Lösung *Engl. Constraint Qualifications (CQ)*
- **Regularitätsvoraussetzungen** garantieren, dass es Lagrange-Multiplikatoren  $(\mu_*, \lambda_*)$  gibt, sodass  $(x_*, \mu_*, \lambda_*)$  ein KKT-Punkt ist

*Lineare NB (Satz 5.12)*

*Abadie CQ (Satz 7.5)*

LICQ (Satz 7.7)

Slater-Bedingung (Satz 7.8)



# Satz 7.7. LICQ (Linear Independence CQ)

- Sei  $x_* \in \mathcal{F}$  und  $\mathcal{A}(x_*)$  die aktive Menge bei  $x_*$ :

$$\begin{aligned}\mathcal{A}(x_*) &= \{i = 1, \dots, m_U : g_i(x_*) = 0\} \\ &= \{i_1, \dots, i_k\}\end{aligned}$$

- Angenommen,  $x_*$  erfüllt die **LICQ**:

$\nabla g_{i_1}(x_*), \dots, \nabla g_{i_k}(x_*), \nabla h_1(x_*), \dots, \nabla h_{m_G}(x_*)$  sind linear unabhängig

- Dann erfüllt  $x_*$  die Abadie CQ:

$$\mathcal{T}_{\mathcal{F}}(x_*) = \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$$



# Beweis

$$h(x) = \begin{bmatrix} h_1(x) \\ \vdots \\ h_{m_G}(x) \end{bmatrix}$$

$$g_{\mathcal{A}(x_*)}(x) := \begin{bmatrix} g_{i_1}(x) \\ \vdots \\ g_{i_k}(x) \end{bmatrix}, \quad Dg_{\mathcal{A}(x_*)}(x) = \begin{bmatrix} \nabla g_{i_1}(x)^T \\ \vdots \\ \nabla g_{i_k}(x)^T \end{bmatrix}, \quad Dh(x) = \begin{bmatrix} \nabla h_1(x)^T \\ \vdots \\ \nabla h_{m_G}(x)^T \end{bmatrix}$$

$$F(x) := \begin{bmatrix} g_{\mathcal{A}(x_*)}(x) \\ h(x) \end{bmatrix} \quad \swarrow x_* \text{ erfüllt LICQ}$$

$$DF(x_*) = \begin{bmatrix} Dg_{\mathcal{A}(x_*)}(x_*) \\ Dh(x_*) \end{bmatrix} \text{ hat vollen Zeilenrang}$$





# Beweis

Sei  $d \in \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$  und  $R(x, t) := F(x) - tDF(x_*)d$

$D_x R(x_*, 0) = DF(x_*)$  hat vollen Zeilenrang und  $R(x_*, 0) = 0$

↪ Satz von der impliziten Funktion

$\exists \varepsilon > 0, \exists y(t) \in C^1([0, \varepsilon), \mathbb{R}^n): \quad R(y(t), t) \equiv 0 \text{ und } y(0) = x_*$



# Beweis

Sei  $d \in \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$  und  $R(x, t) := F(x) - tDF(x_*)d$

$D_x R(x_*, 0) = DF(x_*)$  hat vollen Zeilenrang und  $R(x_*, 0) = 0$

↘ Satz von der impliziten Funktion

$\exists \varepsilon > 0, \exists y(t) \in C^1([0, \varepsilon), \mathbb{R}^n): R(y(t), t) \equiv 0$  und  $y(0) = x_*$

$$g_{\mathcal{A}(x_*)^c}(x_*) < 0$$

$$g_{\mathcal{A}(x_*)}(y(t)) = tDg_{\mathcal{A}(x_*)}(x_*)^T d \leq 0$$

$$h(y(t)) = tDh(x_*)^T d = 0 \quad d \in \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$$

Ableitung in  $t = 0$

$$y(t) = x_* + td + o(t)$$

$$\exists \eta \in (0, \varepsilon): y(t) \in \mathcal{F} \quad \forall t \in [0, \eta]$$

Def.

$$d \in \mathcal{T}_{\mathcal{F}}(x_*)$$



# Satz 7.8. Slater-Bedingung

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $g_i(x) \leq 0, i = 1, \dots, m_U$

$$Ax = b$$

$f, g_i \in C^1(\mathbb{R}^n)$  konvex

- Angenommen, die Slater-Bedingung erfüllt ist:

*Es gibt  $\bar{x} \in \mathbb{R}^n$  so, dass  $g_i(\bar{x}) < 0, i = 1, \dots, m_U$  und  $A\bar{x} = b$*

*Slater-Punkt*

- Dann ist für alle  $x_* \in \mathcal{F}$  die Abadie CQ erfüllt:

$$\mathcal{T}_{\mathcal{F}}(x_*) = \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$$



# Beweis

$\mathcal{T}_{\mathcal{F}}(x_*) \subseteq \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$  im Allgemeinen

$$\mathcal{T}_{\mathcal{F}}^<(x_*) := \{d: Dg_{\mathcal{A}(x_*)}(x_*)d < 0, Dh(x_*)^T d = 0\}$$

Wir beweisen, dass unter der Slater-Bedingung:

1.  $\mathcal{T}_{\mathcal{F}}^{lin}(x_*) \subseteq \overline{\mathcal{T}_{\mathcal{F}}^<(x_*)}$
2.  $\mathcal{T}_{\mathcal{F}}^<(x_*) \subseteq \mathcal{T}_{\mathcal{F}}(x_*)$

Somit erhalten wir, dass  $\mathcal{T}_{\mathcal{F}}(x_*) = \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$



# Beweis

Slater-Punkt  $\bar{x}$ :  $g(\bar{x}) < 0$  und  $A\bar{x} = b$

Behauptung:  $\mathcal{T}_{\mathcal{F}}^{lin}(x_*) \subseteq \overline{\mathcal{T}_{\mathcal{F}}^{<}(x_*)}$  für alle  $x_* \in \mathcal{F}$

Sei  $d \in \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$  und setze:

$$\bar{d}(t) = d + t(\bar{x} - x_*), \quad t > 0$$

$$A\bar{d}(t) = Ad + t(A\bar{x} - Ax_*) = 0$$



# Beweis

Slater-Punkt  $\bar{x}$ :  $g(\bar{x}) < 0$  und  $A\bar{x} = b$

Behauptung:  $\mathcal{T}_{\mathcal{F}}^{lin}(x_*) \subseteq \overline{\mathcal{T}_{\mathcal{F}}^{<}(x_*)}$  für alle  $x_* \in \mathcal{F}$

Sei  $d \in \mathcal{T}_{\mathcal{F}}^{lin}(x_*)$  und setze:  
 $\bar{d}(t) = d + t(\bar{x} - x_*)$ ,  $t > 0$

$$A\bar{d}(t) = Ad + t(A\bar{x} - Ax_*) = 0$$

$$\begin{aligned} i \in \mathcal{A}(x_*): \quad \nabla g_i(x_*)^T \bar{d}(t) &= \nabla g_i(x_*)^T d + t \nabla g_i(x_*)^T (\bar{x} - x_*) \quad \text{Satz 2.17} \\ &\leq \underbrace{\nabla g_i(x_*)^T d}_{\leq 0} + t \underbrace{(g_i(\bar{x}) - g_i(x_*))}_{< 0} \quad \underbrace{= 0} \end{aligned}$$

$$\begin{aligned} \bar{d}(t) &\in \mathcal{T}_{\mathcal{F}}^{>}(x_*) \text{ und } \bar{d}(t) \rightarrow d \text{ für } t \rightarrow +0 \\ &\Rightarrow d \in \overline{\mathcal{T}_{\mathcal{F}}^{<}(x_*)} \end{aligned}$$



# Beweis

Behauptung:  $\mathcal{T}_{\mathcal{F}}^<(x_*) \subseteq \mathcal{T}_{\mathcal{F}}(x_*)$  für alle  $x_* \in \mathcal{F}$

Sei  $d \in \mathcal{T}_{\mathcal{F}}^<(x_*)$  und setze  $x(t) = x_* + td$

$$\begin{aligned} &= 0 \\ g_i(x(t)) &= g_i(x_*) + t \nabla g_i(x_*)^T d + o(t) \quad i \in \mathcal{A}(x_*) \end{aligned}$$

$$= t \left( \underbrace{\nabla g_i(x_*)^T d}_{< 0} + o(1) \right)$$

$$\exists \varepsilon > 0: g_i(x(t)) < 0 \quad \forall t \in (0, \varepsilon)$$

$x(t)$  ist zulässig  $\forall t \in (0, \varepsilon)$

$$\Rightarrow d \in \mathcal{T}_{\mathcal{F}}(x_*)$$

$$Ax(t) = Ax_* = b$$




# Aufgabe 7.9. Snelliussches Brechungsgesetz

- Die Kurve  $h(x) = 0$  mit  $h \in C^1(\mathbb{R}^2)$  trennt zwei Medien mit Lichtgeschwind.  $v_y$  bzw.  $v_z$
- Ein Lichtstrahl reist von  $y$  nach  $z$  entlang des Pfads der minimalen Laufzeit

$$\text{Minimiere } \frac{\|x-y\|_2}{v_y} + \frac{\|x-z\|_2}{v_z} \text{ über } x \in \mathbb{R}^2$$

u.d.N.  $h(x) = 0$



- Beweisen Sie die Formel:  $\frac{\sin(\phi_y)}{v_y} = \frac{\sin(\phi_z)}{v_z}$





# Plan

- KKT-Bedingungen
- Regularitätsvoraussetzungen
- Dualität für konvexe Programme



# Konvexes Programm

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

$f \in C^1(\mathbb{R}^n)$  konvex

u.d.N.  $a_i^T x = b_i, i = 1, \dots, m_G$

$a_i \in \mathbb{R}^n, b_i \in \mathbb{R}$

*Lagrange-Funktion*

$g_i(x) \leq 0, i = 1, \dots, m_U$

$g_i \in C^1(\mathbb{R}^n)$  konvex

$$\mathcal{L}(x, \mu, \lambda) = f(x) + \sum_{i=1}^{m_U} \overset{\geq 0}{\mu_i} g_i(x) + \sum_{i=1}^{m_G} \lambda_i (b_i - a_i^T x)$$

*Das duale Problem*

$G(\mu, \lambda) := \inf_{x \in \mathbb{R}^n} \mathcal{L}(x, \mu, \lambda)$  Die duale Funktion

Maximiere  $G(\mu, \lambda)$  über  $\mu \in \mathbb{R}^{m_U}, \lambda \in \mathbb{R}^{m_G}$

u.d.N.  $\mu \geq 0$



# Satz 7.10. Dualität für konvexe Programme

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $a_i^T x = b_i, i = 1, \dots, m_G$

$g_i(x) \leq 0, i = 1, \dots, m_U$

$f \in C^1(\mathbb{R}^n)$  konvex

$a_i \in \mathbb{R}^n, b_i \in \mathbb{R}$

$g_i \in C^1(\mathbb{R}^n)$  konvex

- Angenommen, die Slater-Bedingung ist erfüllt
- Sei  $x_*$  eine optimale Lösung und  $\mu_*, \lambda_*$  die zugehörigen Lagrange-Multiplikatoren, sodass  $(x_*, \mu_*, \lambda_*)$  ein KKT-Punkt ist (Sätze 8.2, 8.4)
- Dann ist  $\mu_*, \lambda_*$  eine optimale Lösung des dualen Problems und die optimalen Werte im Primalen und im Dualen übereinstimmen



# Beweis

Sei  $(x_*, \mu_*, \lambda_*)$  ein KKT-Punkt

$$\nabla_x \mathcal{L}(x_*, \mu_*, \lambda_*) = 0$$

$\mathcal{L}(\cdot, \mu_*, \lambda_*)$  ist konvex

$$\mathcal{L}(x_*, \mu_*, \lambda_*) \leq \mathcal{L}(x, \mu_*, \lambda_*) \quad \forall x \in \mathbb{R}^n$$

$$\mathcal{L}(x_*, \mu_*, \lambda_*) = f(x_*) + \sum_{i=1}^{m_U} \overbrace{\mu_{*,i} g_i(x_*)}^{=0} + \sum_{i=1}^{m_G} \overbrace{\lambda_{*,i} (b_i - a_i^T x_*)}^{=0}$$



# Beweis

Sei  $(x_*, \mu_*, \lambda_*)$  ein KKT-Punkt

$$\nabla_x \mathcal{L}(x_*, \mu_*, \lambda_*) = 0$$

$\mathcal{L}(\cdot, \mu_*, \lambda_*)$  ist konvex

$$\mathcal{L}(x_*, \mu_*, \lambda_*) \leq \mathcal{L}(x, \mu_*, \lambda_*) \quad \forall x \in \mathbb{R}^n$$

$$\begin{aligned} \mathcal{L}(x_*, \mu_*, \lambda_*) &= f(x_*) + \sum_{i=1}^{m_U} \overbrace{\mu_{*,i} g_i(x_*)}^{=0} + \sum_{i=1}^{m_G} \overbrace{\lambda_{*,i} (b_i - a_i^T x_*)}^{=0} \\ &\geq f(x_*) + \sum_{i=1}^{m_U} \underbrace{\mu_i g_i(x_*)}_{\leq 0} + \sum_{i=1}^{m_G} \underbrace{\lambda_i (b_i - a_i^T x_*)}_{=0} \quad \forall \mu \geq 0, \forall \lambda \\ &= \mathcal{L}(x_*, \mu, \lambda) \end{aligned}$$

$\Rightarrow (x_*, \mu_*, \lambda_*)$  ist ein Sattelpunkt von  $\mathcal{L}$

$\Rightarrow (\mu_*, \lambda_*)$  ist dual optimal und optimale Werte übereinstimmen (Satz 5.14.)  $\square$



# Satz 7.11. Hinreichende Optimalitätsbedingung

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $a_i^T x = b_i, \quad i = 1, \dots, m_G$

$g_i(x) \leq 0, \quad i = 1, \dots, m_U$

$f \in C^1(\mathbb{R}^n)$  konvex

$a_i \in \mathbb{R}^n, b_i \in \mathbb{R}$

$g_i \in C^1(\mathbb{R}^n)$  konvex

- Angenommen, die Slater-Bedingung ist erfüllt
- Sei  $(x_*, \mu_*, \lambda_*)$  ein KKT-Punkt
- Dann ist  $x_*$  eine optimale Lösung des Primalen und  $(\mu_*, \lambda_*)$  eine optimale Lösung des Dualen. Außerdem ist die starke Dualität erfüllt



# Beweis

Sei  $(x_*, \mu_*, \lambda_*)$  ein KKT-Punkt und sei  $x$  zulässig

$$\begin{aligned} f(x) &\geq f(x_*) + \nabla f(x_*)^T (x - x_*) &&= 0 \\ &= f(x_*) - \sum_{i=1}^{m_U} \mu_{*,i} \nabla g_i(x_*)^T (x - x_*) + \sum_{i=1}^{m_G} \overline{\lambda_{*,i} a_i^T (x - x_*)} \end{aligned}$$



# Beweis

Sei  $(x_*, \mu_*, \lambda_*)$  ein KKT-Punkt und sei  $x$  zulässig

$$\begin{aligned} f(x) &\geq f(x_*) + \nabla f(x_*)^T (x - x_*) &&= 0 \\ &= f(x_*) - \underbrace{\sum_{i=1}^{m_U} \mu_{*,i} \nabla g_i(x_*)^T (x - x_*)}_{\leq \mu_{*,i}(g_i(x) - g_i(x_*))} + \underbrace{\sum_{i=1}^{m_G} \lambda_{*,i} a_i^T (x - x_*)}_{\mu_{*,i} g_i(x) \leq 0} \\ &\Rightarrow f(x) \geq f(x_*) &&\text{Komplementaritätsbedingung} \end{aligned}$$

$\Rightarrow x_*$  ist eine optimale Lösung des primalen Problems


$\mu_*, \lambda_*$  ist eine optimale Lösung des Dualen nach Satz 7.10





# Kleinste Umschließende Kugel

- Seien  $x_1, \dots, x_m \in \mathbb{R}^n$  gegeben
- Finde die kleinste Kugel  $B_{R_*}(x_*) = \{x: \|x - x_*\|_2 \leq R_*\}$ , die alle Punkte  $x_1, \dots, x_m$  enthält
- Optimaler Standort einer Notfall-Einrichtung



# Aufgabe 7.12. Kleinste Umschließende Kugel

Minimiere  $\gamma$  über  $\gamma > 0, x \in \mathbb{R}^n$   
u.d.N.  $\|x_i - x\|_2^2 \leq \gamma, i = 1, \dots, m$   $\gamma = R^2$

- Formulieren Sie das duale Problem und klassifizieren Sie sie
- Zeigen Sie, dass die Slater-Bedingung erfüllt ist
- Sei  $\mu_*$  eine optimale Lösung des Dualen. Zeigen Sie, dass die optimale Lösung des primalen ist gegeben durch:

$$x_* = \sum_{i=1}^m \mu_{*,i} x_i$$

*ähnlich zu SVN*



# Zusammenfassung

- Optimalitätsbedingungen
- Regularitätsvoraussetzungen
- Dualität für konvexe Programme



# Nächstes Video

- 7c. Nichtlineare Optimierung: Algorithmen

