

# 7c. Nichtlineare Optimierung

## Algorithmen

Optimierung SoSe 2020

Dr. Alexey Agaltsov



# Plan


- Penalty-Verfahren
- Augmented-Lagrangian-Verfahren
- Barriere-Verfahren



# Quadratische Straffunktion

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $h_i(x) = 0, \quad i = 1, \dots, m$



*Strafparameter*  $> 0$

Minimiere  $Q(x; \beta) = f(x) + \frac{\beta}{2} \sum_{i=1}^m h_i^2(x)$  über  $x \in \mathbb{R}^n$

*Quadratische Straffunktion*

- Bedingungsverletzungen werden bestraft
- Geht  $\beta \rightarrow \infty$ , so nähert sich das unrestringierte Problem an das ursprüngliche restringierte Problem an

# Quadratische Straffunktion

Minimiere  $Q(x; \beta) = f(x) + \frac{\beta}{2} \sum_{i=1}^m h_i^2(x)$  über  $x \in \mathbb{R}^n$

Sei  $\beta^1, \beta^2, \dots$  eine Folge mit  $\beta^k \rightarrow \infty$  und  $x^k = \operatorname{argmin}_x Q(x; \beta^k)$

- Liegt  $\beta^k$  nah an  $\beta^{k-1}$ , so kann man  $x^k$  schnell ausgehend von  $x^{k-1}$  finden
- Ist die Berechnung von  $\operatorname{argmin}_x Q(x; \beta^k)$  aufwendig, so wählt man  $\beta^k$  ein bisschen größer als  $\beta^{k-1}$ , z.B.  $\beta^k = 1.5\beta^{k-1}$
- Ansonsten kann man größere Schritte wählen, z.B.  $\beta^k = 10\beta^{k-1}$



# Satz 7.13. Konvergenz

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $h_i(x) = 0, \quad i = 1, \dots, m$

$f, h_i \in C(\mathbb{R}^n)$

$$Q(x; \beta) = f(x) + \frac{\beta}{2} \sum_{i=1}^m h_i^2(x)$$

- Angenommen, das restringierte Problem besitzt eine optimale Lösung  $x^*$
- Sei  $\beta^1, \beta^2, \dots$  eine Folge mit  $\beta^k \rightarrow \infty$  und sei  $x^k = \operatorname{argmin}_x Q(x; \beta^k)$
- Gelte  $x^k \rightarrow \bar{x}$ , so ist  $\bar{x}$  eine optimale Lösung

# Beweis

$$x^k = \operatorname{argmin}_x Q(x, \beta^k)$$

$$Q(x^k, \beta^k) \leq Q(x^*, \beta^k)$$

$$f(x^k) + \frac{\beta^k}{2} \sum_{i=1}^m h_i^2(x^k) \leq f(x^*) + \frac{\beta^k}{2} \sum_{i=1}^m h_i^2(x^*) = f(x^*)$$

$$f(\bar{x}) \leq f(x^*)$$

$$\sum_{i=1}^m h_i^2(x^k) \leq \frac{2}{\beta^k} (f(x^*) - f(x^k))$$

$$k \rightarrow \infty \rightarrow \sum_{i=1}^m h_i^2(\bar{x}) = 0$$



# Bemerkung

- Man kann die Konvergenz gegen eine optimale Lösung nur dann garantieren, wenn  $x^k = \operatorname{argmin}_x Q(x, \beta^k)$  für alle  $k$
- Es ist einfacher,  $\|\nabla_x Q(x^k, \beta^k)\|_2 \leq \tau^k$  mit  $\tau^k \rightarrow 0$  zu garantieren
- Wir werden die Bedingungen herleiten, die die Konvergenz von  $x^k$  (und gewissen Lagrange-Multiplikatoren) gegen einen KKT-Punkt garantieren



# Das Penalty-Verfahren

1. *Initialisierung*: Startwert  $x^0 \in \mathbb{R}^n$ , Anfangsstrafparameter  $\beta^1 > 0$   
Toleranzwerte  $(\tau^k)$  mit  $\tau^k \rightarrow 0$
2. **for**  $k = 1, 2, 3, \dots$  **do**
3.     **if** *Abbruchskriterium ist erfüllt* **then** STOP
4.     bestimme  $x^k$ , sodass  $\|\nabla_x Q(x^k, \beta^k)\|_2 \leq \tau^k$ , ausgehend von  $x^{k-1}$
5.     bestimme einen Strafparameter  $\beta^{k+1} \geq \beta^k$
6. **end for**





# Satz 7.14. Bestimmung eines KKT-Punktes

Seien  $f, h_i \in C^1(\mathbb{R}^n)$ . Angenommen:

- Seien  $(\tau^k), (\beta^k), (x^k)$  die Folgen mit  $\tau^k \rightarrow 0, \beta^k \rightarrow \infty$  so, dass:

$$\|\nabla_x Q(x^k; \beta^k)\|_2 \leq \tau^k$$

- $x^k \rightarrow \bar{x}$ , wobei  $\bar{x}$  ist so, dass  $\{\nabla h_i(\bar{x})\}_{i=1,\dots,m}$  linear unabhängig sind

Dann  $\lambda^k = \beta^k h(x^k) \rightarrow \bar{\lambda}$ , sodass  $(\bar{x}, \bar{\lambda})$  ein KKT-Punkt ist



# Beweis: $\bar{x}$ ist zulässig

$$\nabla_x Q(x^k, \beta^k) = \nabla f(x^k) + \beta^k \sum_{i=1}^m h_i(x^k) \nabla h_i(x^k)$$

$$\|\nabla f(x^k) + \beta^k \sum_{i=1}^m h_i(x^k) \nabla h_i(x^k)\|_2 \leq \tau^k$$

$$\|\sum_{i=1}^m h_i(x^k) \nabla h_i(x^k)\|_2 \leq \frac{1}{\beta^k} \left( \tau^k + \|\nabla f(x^k)\|_2 \right)$$

$$\sum_{i=1}^m h_i(\bar{x}) \nabla h_i(\bar{x}) = 0 \quad k \rightarrow \infty$$

$$h_i(\bar{x}) = 0, \quad i = 1, \dots, m$$

$\Rightarrow \bar{x}$  ist zulässig

$\{\nabla h_i(\bar{x})\}_i$  linear unabhängig



**Beweis:  $(x^k, \lambda^k)$  strebt gegen einen KKT-Punkt  $(\bar{x}, \bar{\lambda})$**

$$\nabla_x Q(x^k, \beta^k) = \nabla f(x^k) + \beta^k \sum_{i=1}^n h_i(x^k) \nabla h_i(x^k)$$

$$A(x)^T := [\nabla h_1(x), \dots, \nabla h_m(x)]$$

$$\lambda^k = \beta^k h(x^k)$$

$$\nabla_x Q(x^k, \beta^k) = \nabla f(x^k) + A(x^k)^T \lambda^k$$

$$\text{rang}(A(\bar{x})^T) = m$$

$$\lambda^k = \left( A(x^k) A(x^k)^T \right)^{-1} \left( \nabla Q_x(x^k, \beta^k) - \nabla f(x^k) \right) \text{ für großes } k$$

$$\lambda^k \rightarrow \bar{\lambda} = -(A(\bar{x}) A(\bar{x})^T)^{-1} \nabla f(\bar{x})$$

$$\nabla f(\bar{x}) + \sum_{i=1}^m \bar{\lambda}_i \nabla h_i(\bar{x}) = 0$$




# Allgemeine Nebenbedingungen

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $h_i(x) = 0, \quad i = 1, \dots, m_G$

$g_i(x) \leq 0, \quad i = 1, \dots, m_U$



Minimiere  $Q(x; \beta) = f(x) + \frac{\beta}{2} \sum_{i=1}^{m_G} h_i^2(x) + \frac{\beta}{2} \sum_{i=1}^{m_U} ([g_i(x)]^-)^2$   
 $[y]^- = \max\{-y, 0\}$

- Die Straffunktion kann weniger glatt als die Zielfunktion und die Beschränkungsfunktionen sein

$$\max\{-x, 0\} \notin C^1(\mathbb{R})$$



# Plan

- Penalty-Verfahren
- **Augmented-Lagrangian-Verfahren**
- Barriere-Verfahren



# Penalty-Verfahren und systematischer Fehler

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $h_i(x) = 0, \quad i = 1, \dots, m$

- Das Penalty-Verfahren erzeugt eine Folge  $(x^k, \lambda^k)$  die gegen einen KKT-Punkt  $(\bar{x}, \bar{\lambda})$  konvergiert

$$\lambda^k = \beta^k h(x^k), \quad \beta^k \rightarrow \infty$$

$$h(x^k) = \lambda^k / \beta^k \quad \text{systematischer Fehler}$$

- $x^k$  wird im Allgemeinen nur für  $\beta^k \rightarrow \infty$  zulässig sein



# Penalty-Verfahren und systematischer Fehler

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $h_i(x) = 0, \quad i = 1, \dots, m$

- Sei  $x^*$  eine optimale Lösung, die die LICQ erfüllt
- Sei  $\lambda^*$  der zugehörige Vektor der Lagrange-Multiplikatoren, sodass  $(x^*, \lambda^*)$  ein KKT-Punkt ist (Sätze 7.5, 7.7)



# Augmented-Lagrange-Funktion

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $h_i(x) = 0, \quad i = 1, \dots, m$

Minimiere  $\mathcal{L}_A(x, \lambda^k; \beta^k) = f(x) + \sum_{i=1}^m \lambda_i^k h_i(x) + \frac{\beta^k}{2} \sum_{i=1}^m h_i^2(x)$  über  $x \in \mathbb{R}^n$

*Strafparameter* (points to  $\beta^k$ )

*aktuelle Approximation an  $\lambda^*$*  (points to  $\lambda^k$ )

*Augmented-Lagrange-Funktion*





# Augmented-Lagrange-Funktion

Minimiere  $\mathcal{L}_A(x, \lambda^k; \beta^k) = f(x) + \sum_{i=1}^m \lambda_i^k h_i(x) + \frac{\beta^k}{2} \sum_{i=1}^m h_i^2(x)$  über  $x \in \mathbb{R}^n$

Sei  $x^{k+1}$  eine optimale Lösung

$$\nabla \mathcal{L}_A(x^{k+1}, \lambda^k; \beta^k) = \nabla f(x^{k+1}) + \sum_{i=1}^m \underbrace{(\lambda_i^k + \beta^k h_i(x^{k+1}))}_{\lambda_i^{k+1}} \nabla h_i(x^{k+1}) = 0$$

- Der KKT-Punkt  $(x^*, \lambda^*)$  erfüllt:

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla h_i(x^*) = 0$$

$$\lambda_i^{k+1} := \lambda_i^k + \beta^k h_i(x^{k+1})$$



# Neue Approximation

$$\lambda_i^{k+1} = \lambda_i^k + \beta^k h_i(x^{k+1})$$

$$h_i(x^{k+1}) = (\lambda_i^{k+1} - \lambda_i^k) / \beta_k$$

- Ist  $\lambda_i^k \rightarrow \lambda_i^*$ , so  $h_i(x^k) = o(1/\beta_k)$

*schneller als für das Penalty-Verfahren*

- Unter gewissen allgemeinen Voraussetzungen  $\exists \bar{\beta} > 0$  so, dass  $x^*$  ein striktes lokales Minimum von  $\mathcal{L}_A(x, \lambda^*; \beta)$  ist  $\forall \beta \geq \bar{\beta}$  [NW, Thm. 17.5]

*$\beta^k \rightarrow \infty$  ist nun nicht erforderlich*

*$\lambda^*$  ist in der Realität nicht bekannt*



# Konvergenz [NW, Thm. 17.6]

- Unter gewissen allgemeinen Voraussetzungen und für alle  $(x^0, \lambda^0)$  hinreichend nah an  $(x^*, \lambda^*)$  gibt es  $M > 0$  so, dass:

$$\|\lambda^{k+1} - \lambda^*\|_2 \leq M \|\lambda^k - \lambda^*\|_2 / \beta_k \quad k = 1, 2, \dots$$

$$\|x^k - x^*\|_2 \leq M \|\lambda^k - \lambda^*\|_2 / \beta_k \quad k = 1, 2, \dots$$



# Das Augmented-Lagrangian-Verfahren

1. *Initialisierung*: Startwerte  $x^0 \in \mathbb{R}^n$ ,  $\lambda^0 \in \mathbb{R}^m$ , Strafparameter  $\beta^0 > 0$
2. **for**  $k = 0, 1, 2, \dots$  **do**
3.     **if** *Abbruchskriterium ist erfüllt* **then** STOP
4.     bestimme  $x^{k+1} = \operatorname{argmin}_x \mathcal{L}_A(x, \lambda^k; \beta^k)$  ausgehend von  $x^k$
5.      $\lambda^{k+1} := \lambda^k + \beta^k h(x^{k+1})$
6.     bestimme einen Strafparameter  $\beta^{k+1} \geq \beta^k$
7. **end for**



# Plan

- Penalty-Verfahren
- Augmented-Lagrangian-Verfahren
- **Barriere-Verfahren**



# Ungleichungsrestringiertes Problem

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $g_i(x) \leq 0, i = 1, \dots, m$

$f, g_i \in C^2(\mathbb{R}^n)$  konvex

- Sei die Slater-Bedingung erfüllt:

$$\exists \bar{x} \in \mathbb{R}^n \text{ mit } g_i(\bar{x}) < 0, i = 1, \dots, m$$

- Sei der optimale Funktionswert endlich:  $f^* > -\infty$



# Logarithmische-Barriere-Funktion

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $g_i(x) \leq 0, i = 1, \dots, m$

*Zentrierungsproblem*

$$\phi(x) = -\sum_{i=1}^m \log(-g_i(x))$$

$U = \{x: g_i(x) < 0, i = 1, \dots, m\}$   
offen, nichtleer

Minimiere  $f(x) + \frac{1}{t}\phi(x)$  über  $x \in U$

*Anpassungsparameter  $> 0$*



# Ableitungen der Barriere-Funktion

$$\phi(x) = -\sum_{i=1}^m \log(-g_i(x))$$

$$\nabla \phi(x) = -\sum_{i=1}^m \frac{1}{g_i(x)} \nabla g_i(x)$$

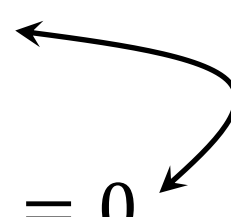




# Zentraler Pfad

Minimiere  $f(x) + (1/t)\phi(x)$  über  $x \in U$

- Angenommen, es gibt eine eindeutige Lösung  $x^*(t)$  für alle  $t > 0$
- $x^*(t)$  heißt **zentraler Punkt** und  $\{x^*(t): t > 0\}$  **zentraler Pfad**
- Optimalitätsbedingung:


$$\begin{aligned} \nabla f(x^*(t)) + (1/t)\nabla\phi(x^*(t)) &= 0 \\ \nabla f(x^*(t)) + \sum_{i=1}^m \boxed{\frac{1}{-tg_i(x^*(t))}} \nabla g_i(x^*(t)) &= 0 \\ &\stackrel{=:}{=} \mu_i^*(t) \end{aligned}$$




# Erinnerung: Dualität

Minimiere  $f(x)$  über  $x \in \mathbb{R}^n$

u.d.N.  $g_i(x) \leq 0, i = 1, \dots, m$



$$\mathcal{L}(x, \mu) = f(x) + \sum_{i=1}^m \mu_i g_i(x)$$

$$G(\mu) = \inf_{x \in \mathbb{R}^n} \mathcal{L}(x, \mu)$$

Maximiere  $G(\mu)$  über  $\mu \in \mathbb{R}^m$

u.d.N.  $G(\mu) > -\infty$    $\mu \geq 0$

Slater-Bedingung



# Satz 7.15. $\varepsilon$ -Optimalität des zentralen Punkts

Sei  $x^*(t)$  ein zentraler Punkt und setze:

$$\mu_i^*(t) = \frac{1}{-tg_i(x^*(t))}, \quad i = 1, \dots, m$$

Es gelten die folgenden Aussagen:

- $x^*(t), \mu^*(t)$  sind zulässige Primal- bzw. Dualpunkte und es gilt:

$$f(x^*(t)) - G(\mu^*(t)) = m/t$$

- Folglich sind  $x^*(t), \mu^*(t)$   $\varepsilon$ -optimal mit  $\varepsilon = m/t$ :

$$f(x^*(t)) - f^* \leq m/t$$

$$f^* - G(\mu^*(t)) \leq m/t$$



Beweis:  $\mu^*(t)$  ist dual zulässig, d.h.  $G(\mu^*(t)) > -\infty$

$$\nabla f(x^*(t)) + \sum_{i=1}^m \boxed{\frac{1}{-tg_i(x^*(t))}} \nabla g_i(x^*(t)) = 0 \quad \begin{matrix} \parallel \\ \mu_i^*(t) \end{matrix}$$

$f, g_i$  konvex

$$\nabla f(x^*(t)) + \sum_{i=1}^m \mu_i^*(t) \nabla g_i(x^*(t)) = 0$$

$x^*(t)$  minimiert  $\mathcal{L}(x, \mu^*(t)) = f(x) + \sum_{i=1}^m \mu_i^*(t) g_i(x)$

$$G(\mu^*(t)) = \mathcal{L}(x^*(t), \mu^*(t)) > -\infty$$

$\mu^*(t)$  ist dual zulässig



# Beweis

$$G(\mu^*(t)) = \mathcal{L}(x^*(t), \mu^*(t))$$

$$= f(x^*(t)) + \sum_{i=1}^m \mu_i^*(t) g_i(x^*(t)) \quad \mu_i^*(t) = \frac{1}{-t g_i(x^*(t))}$$

gewünschte Formel

$$= f(x^*(t)) - \frac{m}{t}$$

Schwache Dualität (Satz 5.13):

$$f(x^*(t)) \geq f^* \geq G(\mu^*(t))$$

$$f(x^*(t)) - f^* \leq m/t$$

$$f^* - G(\mu^*(t)) \leq m/t$$



# Das Barriere-Verfahren

1. *Initialisierung*: Slater-Punkt  $x^0 \in \mathbb{R}^n$ , Parameter  $t^0 > 0$ , Toleranzwert  $\varepsilon$
2. **for**  $k = 0, 1, 2, \dots$  **do**
3.     bestimme  $x^{k+1} = \operatorname{argmin}_x (t^k f(x) + \varphi(x))$  ausgehend von  $x^k$
4.     **if**  $m/t^k < \varepsilon$  **then**: STOP *Zentrierungsschritt*
5.     wähle  $t^{k+1} > t^k$
6. **end for**



# Das Barriere-Verfahren

1. *Initialisierung*: Slater-Punkt  $x^0 \in \mathbb{R}^n$ , Parameter  $t^0 > 0$ , Toleranzwert  $\varepsilon$
  2. **for**  $k = 0, 1, 2, \dots$  **do**
  3.     bestimme  $x^{k+1} = \operatorname{argmin}_x (t^k f(x) + \varphi(x))$  ausgehend von  $x^k$
  4.     **if**  $m/t^k < \varepsilon$  **then**: STOP *Zentrierungsschritt*
  5.     wähle  $t^{k+1} > t^k$
  6. **end for**
- für große  $t^k$  kann schlecht konditioniert sein  
 $x^{k+1}$  muss hinreichend nah an  $x^k$  sein*



# Interpretation: Kräfteausgleich

Minimiere  $f(x)$


u.d.N.  $g_i(x) \leq 0, i = 1, \dots, m$

Minimiere  $t f(x) + \underbrace{\sum_{i=1}^m -\log(-g_i(x))}_{\varphi}$

- $i$ -ter UNB entspricht die Kraft:

$$F_i(x) = \nabla \log(-g_i(x)) = \frac{\nabla g_i(x)}{g_i(x)}$$

- Die logarithmische Barriere-Funktion  $\varphi$  ist das skalare Potenzial, das die resultierende Kraft der UNB erzeugt





# Interpretation: Kräfteausgleich

Minimiere  $tf(x) + \sum_{i=1}^m -\log(-g_i(x))$


- Der Zielfunktion entspricht das Kraftfeld  $tZ(x)$  mit:

$$Z(x) = -\nabla f(x)$$

- Optimalitätsbedingung:

$$\underbrace{-t\nabla f(x^*(t))}_{tZ(x^*(t))} + \underbrace{\sum_{i=1}^{m_U} \frac{\nabla g_i(x^*(t))}{g_i(x^*(t))}}_{F_i(x^*(t))} = 0$$

*Die Kräfte sind im Gleichgewicht*



# Zusammenfassung

- Penalty-Verfahren
- Augmented-Lagrangian-Verfahren
- Barriere-Verfahren



# Nächstes Video

- 8a. Diskrete Optimierung: Netzwerkflussprobleme

